SCC0245 · PROCESSAMENTO ANALÍTICO DE DADOS · PROJETO 1

Rede Municipal Paulistana: oferta escolar e demanda não atendida

Um data warehouse para decidir onde abrir vagas, com dados abertos da SME-SP e do IBGE

Profa. Dra. Cristina Dutra de Aguiar · ICMC-USP, São Carlos

GRUPO 7

Kevenn Laranjeira de Oliveira · Nº USP 18046529
Thiago Rodrigues Gouveia da Silva · Nº USP 18066911
Daniel Afonso Borges dos Santos · Nº USP 12608581
Luís Antônio Arruda Soares · Nº USP 12559486

13,4 mi
matrículas de 2015 a 2024

44
meses de fila por distrito

26.889
setores censitários do Censo 2022

Em dez anos, a fila de creche caiu 97%

A falta de vaga em creche foi por anos o principal problema de acesso da educação infantil em São Paulo.

PNE (Lei 13.005/2014), Meta 1: creche para ao menos metade das crianças de até 3 anos; pré-escola universal.

A cidade avançou: a demanda de creche fora da rede passou de 34% para 1%.

Fonte: Demanda Registrada e Matrículas (SME-SP); consulta 5 sobre a carga com os dados reais.

FILA DE CRECHE EM JUNHO

2015

124.741

crianças · 34% da demanda fora da rede

-97%

2024

3.633

crianças · 1% da demanda fora da rede

E se fosse o seu filho?

3.633

crianças ainda esperavam vaga em creche em junho de 2024, em todos os 96 distritos

SEU FILHO

Meses fora da creche. Poderia chegar à escola atrás das crianças que tiveram educação infantil.

SEU TRABALHO

Faltas, um cuidador pago ou o emprego deixado de lado até a vaga sair.

SUA CASA

Avós, vizinhos e irmãos mais velhos cobrindo o horário da creche.

A fila caiu 97%. Para essas famílias, a espera continua.

Fonte: Demanda Registrada e Matrículas (SME-SP), junho de 2024. As consequências são um cenário ilustrativo.

O problema: saber onde abrir a próxima vaga

Quem aceita qualquer unidade não espera muito: em junho de 2024, nenhuma criança desse grupo estava na fila havia mais de 30 dias.

Quase sete em cada dez crianças da fila esperavam uma unidade específica, escolhida pela família.

A fila está nos 96 distritos, e a oferta vai de menos de 50 a mais de 100 matrículas por 100 crianças (Censo 2022).

FILA DE CRECHE, JUNHO DE 2024

3.633

crianças esperando vaga

2.502 esperavam uma unidade específica, escolhida pela família

1.131 aceitavam qualquer unidade; nenhuma esperava havia mais de 30 dias

Fonte: Demanda Registrada e Matrículas (SME-SP), junho de 2024, no fato Fila; Censo 2022 (IBGE), consulta 7.

Hoje, os dados se repetem e não conversam

1 Matrícula contada em dobro

Junho de 2022: 378.954 matrículas de creche ativas no microdado, mas 340.085 alunos.

A rede parece atender 38.869 crianças a mais.

2 Escolas diferentes, um código só

2024: 193 códigos para 4.011 escolas, em notação científica.

Não dá para saber em qual escola está a vaga.

3 Totais que não fecham

Fila de junho de 2023: a soma dos distritos dá 2.926 crianças com opção; o total publicado, 2.904.

Cada área pode chegar a um número diferente.

4 Zero que não é zero

Até setembro de 2020, a fila não separava quem esperava havia mais de 30 dias.

Gravar zero faria essa espera sumir.

Fonte: nossa carga com os dados reais da SME-SP; o tratamento de cada caso está em docs/04 e no bloco 2.

Nossa solução: as três bases num data warehouse

HOJE

Três bases que não conversam

- **Fila:** planilha por distrito, publicada em sete formatos diferentes.
- **Matrícula:** 13,4 milhões de linhas; de 2022 a 2024 o código da escola chega corrompido.
- **População:** Censo do IBGE, por setor censitário e em faixas de cinco anos.
- Nem o distrito é escrito igual: AGUA RASA na SME, Água Rasa no IBGE.

COM O NOSSO DATA WAREHOUSE

Uma pergunta, uma consulta

- Um comando baixa, limpa, carrega e confere os dados do portal da prefeitura e do IBGE.
- Cinco fatos e catorze dimensões que se cruzam por distrito, etapa e data.
- 14 verificações de qualidade a cada carga; na carga real, nenhuma deu FALHA.
- Oito consultas OLAP respondem às perguntas do gestor.

Quem usa: a Secretaria Municipal de Educação e as 13 Diretorias Regionais, para decidir onde abrir a próxima vaga.

Consultas mais confiáveis e mais rápidas

MAIS RÁPIDA

0,42 s

para as oito consultas OLAP, somadas, sobre 13,4 milhões de matrículas

MAIS RÁPIDA

3,5 min

para carregar tudo no banco, com um comando

MAIS CONFIÁVEL

14

verificações a cada carga; nenhuma FALHA na carga real

MAIS CONFIÁVEL

< 1%

de diferença entre as bases da SME de 2015 a 2020; depois, a diferença fica à vista

Uma linguagem só

Distrito, etapa e idade com a mesma representação nas três bases; nulo quer dizer não publicado, nunca zero; a contagem em dobro do microdado fica ao lado da matrícula da planilha. A Secretaria e as 13 Diretorias olham o mesmo número.

Do dado à vaga: como a fila pode cair mais

1. Medir

A fila de cada distrito e etapa, a cada publicação, separando quem espera uma unidade específica.

fato Fila

2. Localizar

Onde a fila resiste e onde a oferta por criança é menor.

C1 C5 C7

3. Decidir

Turma nova ou lugar ocioso, pela ocupação das turmas, e por qual rede abrir a vaga.

C3 C4 C8

4. Acompanhar

A publicação seguinte mostra se a fila do distrito caiu; o ciclo recomeça.

C1 C5

Quase sete em cada dez crianças da fila de creche esperavam uma unidade específica: falta vaga no lugar certo, e é isso que o ciclo procura.

Por que São Paulo, e não São Carlos

PRIMEIRA PROPOSTA

São Carlos

Oferta escolar por setor censitário. Sem dado aberto de vaga nem de fila, a demanda não atendida teria de ser estimada.

ESCOLHA

São Paulo

A SME publica o microdado de cada matrícula e a fila de espera por distrito: demanda medida, não estimada. 13,4 milhões de matrículas de 2015 a 2024.

O modelo vale para São Carlos: matrícula, turma e desfecho vêm do registro que todo sistema de gestão escolar mantém, e o Censo 2022 já tem a população por setor censitário do município. Falta só a rede registrar e publicar a fila.

Cinco assuntos de interesse e por que importam

Matrículas

oferta efetivamente usada, com o perfil de cada aluno

fato Matrícula

Fila (demanda registrada)

quem pediu vaga e não foi atendido

fato Fila

Capacidade e ocupação das turmas

se a oferta existente está cheia: turma nova ou lugar ocioso

fato Ocupação de Turma

População em idade escolar

demanda potencial, mesmo sem pedido de vaga

fato População

Oferta escolar por setor

onde e por qual rede (direta ou conveniada) a vaga é oferecida

dimensões Escola, Território e Setor

Quinto processo: desfecho da matrícula. Acompanha o que acontece depois do acesso: aprovação, reprovação, abandono e transferência.

Imagine que a prefeitura adote a nossa proposta

1

Kevenn Laranjeira de Oliveira

Slides 1 a 11

O problema e a proposta

A fila que ainda existe, a proposta, os ganhos, São Paulo e os assuntos.

2

Thiago Rodrigues Gouveia da Silva

Slides 12 a 17

Passo 1: os dados

Fontes, integração, problemas nos dados, grão e a estrela Matrícula.

3

Daniel Afonso Borges dos Santos

Slides 18 a 22

Passo 2: o modelo

Estrelas Fila, Desfecho, Ocupação de Turma e População; constelação.

4

Luís Antônio Arruda Soares

Slides 23 a 29

Passo 3: as respostas

Consultas, resultados, decisões e um exemplo de onde abrir vaga.

A adoção é um cenário hipotético; os números vêm da nossa carga com os dados reais.

Três fontes, três perguntas sobre cada distrito

SME-SP · ANUAL

Quem já tem vaga?

Microdados de Matrículas

13,4 mi

matrículas, 2015 a 2024

UMA LINHA É

um aluno numa turma, num ano letivo

SME-SP · TRIMESTRAL E BIMESTRAL

Quem espera vaga?

Demanda Registrada e Matrículas

44 meses

de fila, 96 distritos em cada mês

UMA LINHA É

um distrito num mês, com uma coluna por etapa

IBGE · CENSO 2022

Quantas crianças moram ali?

Agregados por Setores Censitários

26.889

setores, 11,4 milhões de moradores

UMA LINHA É

um setor censitário, com uma coluna por faixa de idade

O exemplo que vamos seguir: o Tremembé. Em junho de 2024, **153** crianças esperavam creche lá; o Censo conta **11.498** crianças de 0 a 4 anos morando no distrito; e cada matrícula das escolas do distrito é uma linha do microdado.

Integração: o mesmo dado, escrito de jeitos diferentes

COMO CHEGA	REGRA	NO DATA WAREHOUSE
Distrito fila: `TREMEMBE` (matrícula: `TREMEMBE`, IBGE: `Tremembé`)	→ maiúsculas, sem acento, sem espaço sobrando	→ **TREMEMBE**: uma única linha da dimensão Território
Idade matrícula: idade exata `2 anos`; IBGE: só o grupo `0 a 4 anos`	→ cada idade ganha a faixa do IBGE em que cai	→ matrícula e população comparadas na **mesma faixa**, 0 a 4 anos
Setor SME: setor administrativo `CD_SETOR, 4 dígitos`; IBGE: setor censitário `CD_SETOR, 15 dígitos`	→ mesmo nome, coisas diferentes: um **homônimo**	→ dois atributos com nomes distintos, **nunca cruzados**

< 1%

Como sabemos que deu certo? Contamos a mesma coisa nas duas bases da SME: as matrículas de creche ativas em junho de 2015 foram **240.905** no microdado e **240.840** na planilha da fila. De 2015 a 2020 a diferença fica abaixo de 1%.

Problemas nos dados (1 de 2): escola, fila e turno

1 Código da escola

COMO CHEGOU · exemplo no formato do arquivo

ano	código publicado	escola
2021	19459	UNIAO DE VILA NOVA I
2022	9209611322271640	UNIAO DE VILA NOVA I
2023	9,20961E+15	UNIAO DE VILA NOVA I
2023	9,20961E+15	BEIJA FLOR ← **mesmo código, outra escola**

O QUE FIZEMOS

1. Mede cada ano no dado: tem “E+” ou um código em duas escolas? Ano corrompido.
2. Procura a escola por **nome + tipo + distrito** em 2021, o último ano confiável.
3. Um código só: copia (volta a ser 19459). Ambíguo ou escola nova: chave `SINT-....`

94,8% a 98,6% das matrículas de 2022 a 2024 com o código real.

2 Planilha de fila em sete formatos

COMO CHEGOU · a mesma coluna (2), dois sentidos

`set/2019` *“(2) - Demanda que recusou vaga oferecida e optou por aguardar numa unidade específica”*

`abr/2024` *“(2) - Demanda sem opção por unidade específica em espera a mais de 30 dias”*

O QUE FIZEMOS

1. Lê as duas linhas de cabeçalho: grupo e etapa de cada coluna, sem posição fixa.
2. Traduz cada nota (n) do rodapé por palavras-chave: “mais de 30”, “unidade específica”.
3. Nota desconhecida: a carga **para**, em vez de gravar o número com sentido errado.

Nenhum número entra trocado; o que não foi publicado fica nulo.

3 Turno não publicado em 2021

COMO CHEGOU

ano	código	descrição	horário
2020	6	INTEGRAL	7h às 17h
2021	9	(vazia)	7h às 17h
2022 (19.954 linhas)	(vazio)	(vazia)	7h às 17h

O QUE FIZEMOS

1. Usa a descrição publicada, quando existe.
2. Em 2021, código − 3 = código de 2020: 9 − 3 = 6, integral. Conferido pelo horário.
3. Sem descrição nem código: pelo horário (noite após 18h; integral com 7 h ou mais).

Cada turno guarda a origem: publicado, código de 2021 ou horário.

Problemas nos dados (2 de 2): idade, datas e IBGE

4 Idade em formato errado

COMO CHEGOU

ano	idade publicada	nascimento
2020	5,00	
2021	(vazia)	05/2018
2022	122	1900
2022	(vazia)	mês 18

O QUE FIZEMOS

1. Idade publicada entre 0 e 99 (aceita “5,00”): usa.
2. Senão, calcula em 31/03: 2021 − 2018 − 1 (nasceu depois de março) = 2 anos.
3. Mês impossível: estima pelo ano e marca “estimada”. Antes de 1901: não informada.

A idade alimenta a faixa de 0 a 4 anos comparada com o Censo.

5 Datas em cinco formatos

COMO CHEGOU

como chega	quando
2019-02-04 00:00:00	2015-2019 e 2022
1/10/2020 00:02:24	2020
01/02/2023 00:00	2023-2024
45397	metade de 2024

O QUE FIZEMOS

1. Cinco dígitos: serial do Excel, dias desde 30/12/1899. 45397 = 15/04/2024.
2. Senão, tenta os formatos de texto um por um. 2021 não tem data: “não informada”.
3. Fora de 1º/1 do ano anterior a 31/12 do ano seguinte: data descartada.

Com início e fim, sabemos quem estava matriculado em 30 de junho.

6 Valores suprimidos pelo IBGE

COMO CHEGOU · exemplo ilustrativo

setor censitário	0 a 4 anos	5 a 9 anos
3550308…	37	41
3550308…	X	X

O QUE FIZEMOS

1. Só dígitos viram número; o X vira **nulo**: “não publicado”.
2. Conta os nulos: 6.543 na carga real, e a verificação Q12 avisa.
3. Se a maioria dos valores não for número, a leitura para: o layout do arquivo mudou.

Nulo não é zero: zero diria “nenhuma criança mora ali”.

Grão: o que é uma linha. Aditividade: o que soma.

GRÃO = O QUE UMA LINHA REPRESENTA

fato Fila

TREMEMBE	jun/2024	CRECHE	153

fato Matrícula

um aluno	uma turma	2024	1

Uma criança não é uma linha da fila: **é uma das 153**. Quando consegue a vaga, vira uma linha do fato Matrícula.

ADITIVIDADE = POSSO SOMAR?

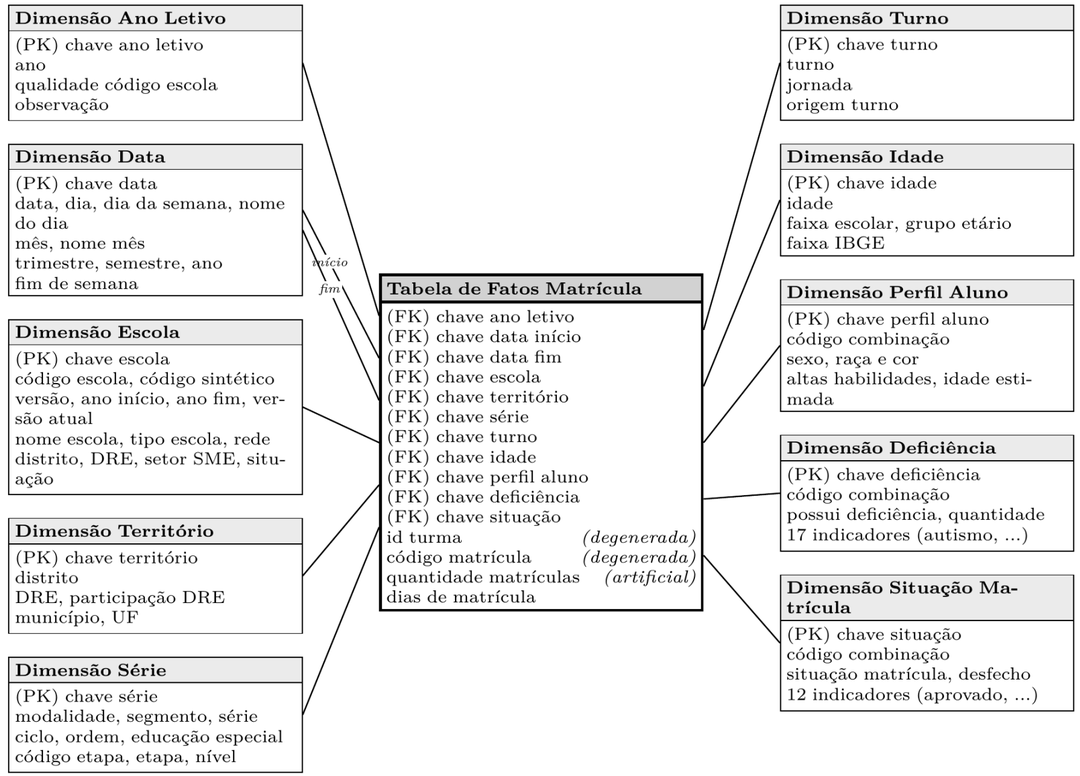
✓ **Somar distritos:** Tremembé + Grajaú em junho de 2024 = 153 + 88 = 241 crianças na fila.

✗ **Somar meses:** fila de abril + fila de junho conta duas vezes quem continuou esperando. A fila é um **estoque**.

÷ **Taxas e médias:** nunca somar nem tirar média; recalcular das somas (abandonos ÷ matrículas).

Tabela de fatos	Uma linha é	Pode somar?
Matrícula	um vínculo aluno-turma × ano	**aditivo**: soma em tudo
Fila	distrito × mês × etapa	**semiaditivo**: soma distritos e etapas, não meses
Desfecho	escola × ano × série	**aditivo** nas contagens; taxas recalculadas
Ocupação de Turma	turma × ano	**aditivo** nas contagens; alunos por turma recalculado
População	setor censitário × faixa × Censo	**semiaditivo**: soma setores e faixas, não Censos

Esquema estrela Matrícula



CADA RECURSO RESOLVE UM PROBLEMA

1. **Data com dois papéis** (início e fim): diz se a matrícula estava ativa em 30 de junho, o número que se compara com a fila.
2. **Campo igual a 1** em cada linha: contar matrículas vira uma soma. Dias de matrícula é a outra medida.
3. **Bugigangas** (Perfil, Deficiência, Situação): mais de 30 indicadores em 3 dimensões, e não em 30.
4. **Degeneradas** (id da turma, código da matrícula): identificadores que ficam no fato, sem tabela própria.
5. **Escola tipo 2**: a escola que muda de nome ganha uma versão nova, e a matrícula antiga guarda o nome da época.

Esquema estrela Fila



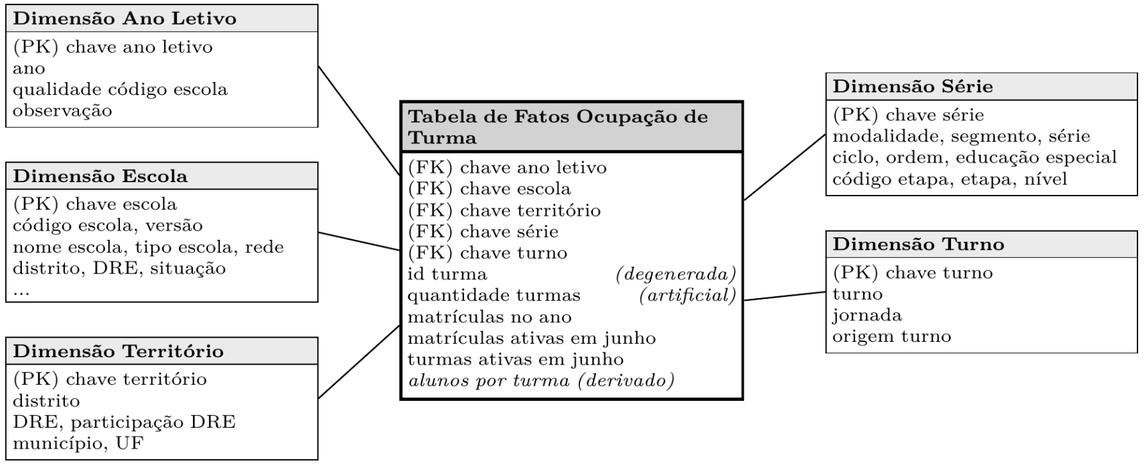
- Grão: distrito × mês × etapa.
- Estoque: SOMA no território e na etapa; um único mês no tempo.
- Formato da planilha: dimensão degenerada.
- Tempo: mês ≤ trimestre ≤ semestre ≤ ano e mês ≤ bimestre ≤ ano.
- Território: distrito ≤ DRE ≤ município ≤ UF.

Esquema estrela Desfecho



- Grão: escola × ano letivo × série.
- Fato agregado do fato Matrícula.
- Contagens por desfecho: SOMA.
- Taxas derivadas, não aditivas: recalculadas pelas contagens.
- Série: série ≤ etapa ≤ nível.

Esquema estrela Ocupação de Turma



- Grão: turma × ano letivo.
- Turmas (= 1), matrículas e ativas em 30/06: SOMA.
- Alunos por turma: derivado, recalculado pelas somas.
- Capacidade não publicada por nenhuma fonte: não é estimada.
- id turma: dimensão degenerada.

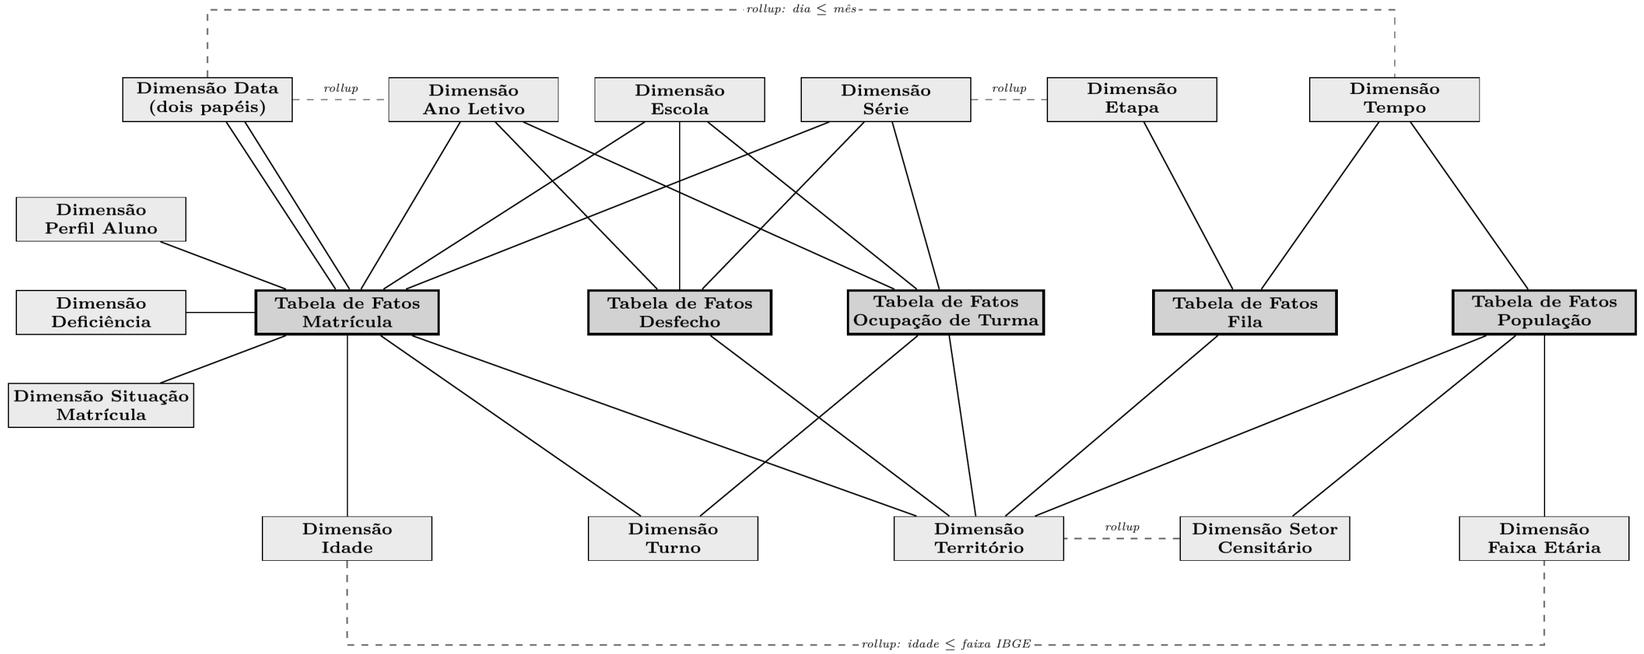
Esquema estrela População



- Grão: setor censitário × faixa etária × data do Censo.
- Estoque: SOMA entre setores e faixas, não no tempo.
- Valor suprimido pelo IBGE fica nulo.
- Setor censitário ≤ distrito ≤ DRE ≤ município ≤ UF.
- Faixa Etária: rollup encolhido de Idade.

Constelação de fatos

5 fatos | 14 dimensões | Território nos cinco fatos



Processo de projeto: matriz de barramento (fato × dimensão), dimensões conformadas e, onde os grãos diferem, rollups encolhidos (tracejado).

Oito consultas OLAP

Exigido: 2 roll-up ou drill-down, 1 slice and dice, 1 pivot, 1 drill-across.
Feito: 3, 1, 1 e 3.

C1 drill-down

Fila de creche: município → DRE → distrito

528 crianças

em dez/2024; Ipiranga lidera (103)

Fila

C2 roll-up

Matrículas: etapa → nível → total, ano a ano

1,42 milhão

de matrículas em 2024; creche +48% desde 2015

Matrícula

C3 slice and dice

Creche por rede e jornada, 2019 e 2024

85% conveniada

e quase toda em jornada integral, nos dois anos

Matrícula

C4 pivot

DRE nas linhas, jornada nas colunas

35,5% a 47,2%

em jornada integral, por DRE (2024)

Matrícula

C5 drill-across

Fila contra matrícula ativa em junho, por distrito

-97%

na fila de creche em junho, de 2015 a 2024

Fila e Matrícula

C6 drill-across

Fila de creche e abandono no fundamental, por DRE

-0,27 a 0,56

correlação nas 13 DREs; o sinal muda entre os anos

Fila, Matrícula e Desfecho

C7 drill-across

0 a 4 anos: residentes, matriculadas e na fila

86 por 100

matrículas por 100 crianças residentes (31/07/2022)

População, Matrícula e Fila

C8 drill-down

Alunos por turma: município → DRE → distrito

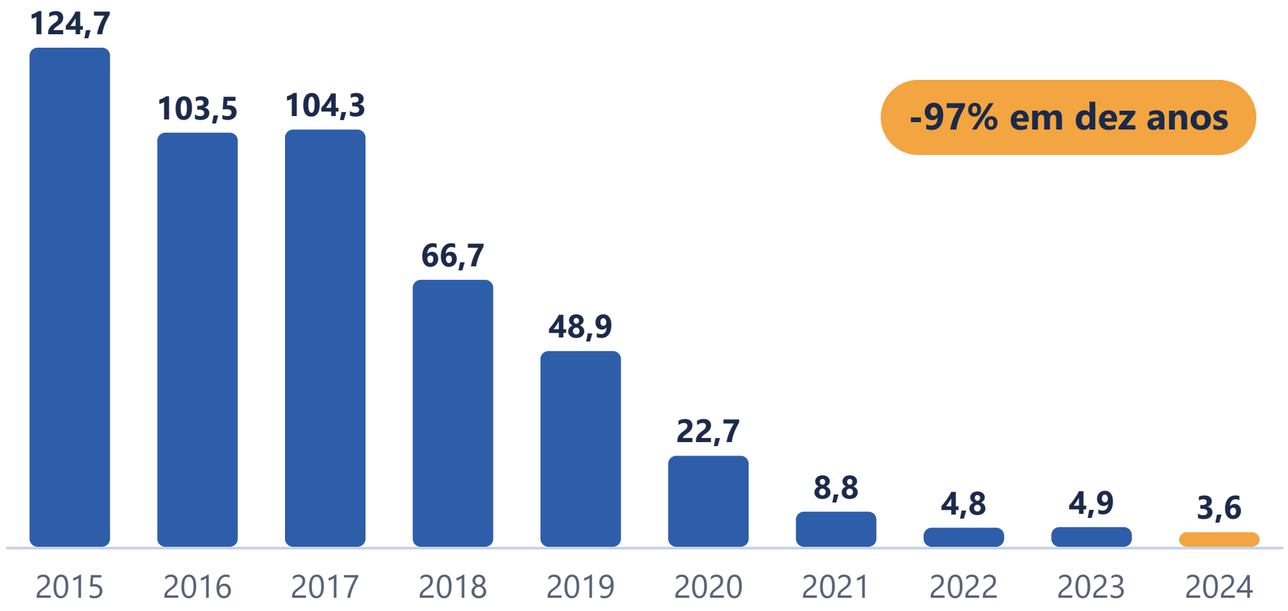
11 por turma

na creche; de 28,7 a 31,6 no fundamental

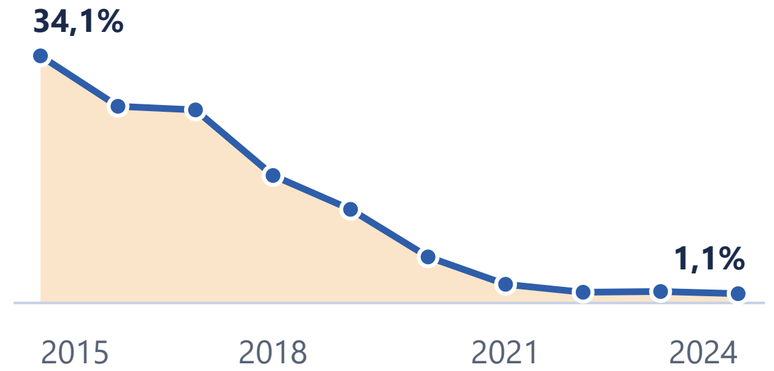
Ocupação de Turma

Resultados: fila e oferta de creche

Crianças na fila de creche em junho, em milhares (consulta 5)



Fração da demanda de creche fora da rede



85% da creche é conveniada, quase toda em jornada integral, em 2019 e em 2024 (consulta 3).

Fonte: SME-SP, Demanda Registrada e Matrículas e Microdados de Matrículas; consultas 3 e 5.

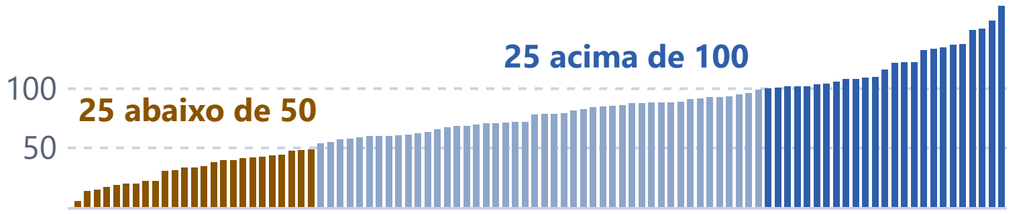
Resultados: população e ocupação das turmas

CONSULTA 7 · 31/07/2022

86 **matrículas por 100 crianças de 0 a 4 anos**

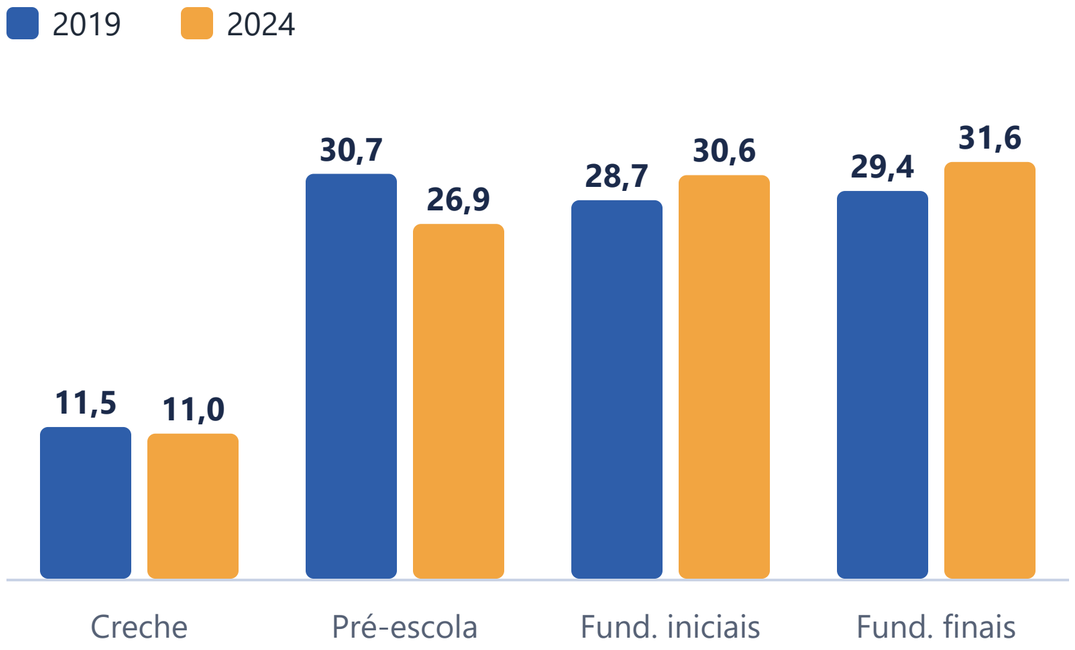
514.131 matrículas ativas para 598.406 crianças residentes.

Por distrito, longe da média (96 distritos)



Extremos: Jardim Paulista (4,7) e Lajeado (169,7). A matrícula conta onde a escola fica.

Alunos por turma em 30 de junho (consulta 8)



Fonte: Censo 2022 (IBGE) e Microdados de Matrículas (SME-SP); consultas 7 e 8.

Decisões de projeto em destaque

1 **Grão mais fino na matrícula**

vínculo aluno-turma: preserva perfil e desfecho de cada aluno

2 **Rollups encolhidos**

cada fato mantém o seu grão; Etapa, Tempo, Faixa Etária e Território conformam

3 **Nulo não é zero**

medida não publicada fica nula; zero faria a fila sumir

4 **Escola tipo 2**

402 escolas mudam de nome, tipo, distrito ou DRE na série

5 **Capacidade não inventada**

ocupação medida pelos alunos ativos; nenhuma vaga estimada

6 **Datas de referência**

junho para fila × matrícula; 31/07/2022 para população × matrícula

Um exemplo: a próxima vaga vai para o Tremembé

GRAJAÚ · O MAIOR DISTRITO

24.398 crianças de 0 a 4 anos (Censo 2022)

82,7 matrículas por 100 crianças (2022)

88 na fila de creche em junho de 2024; eram 8.018 em 2015

TREMEMBÉ

11.498 crianças de 0 a 4 anos (Censo 2022)

71,6 matrículas por 100 crianças, abaixo da média de 86

153 na fila de creche em junho de 2024, a segunda maior da cidade

O que o cruzamento mostra: pelo tamanho, a escolha seria o Grajaú; com fila, oferta e população lado a lado, a próxima vaga pesa mais no Tremembé.

Fonte: consultas 5 e 7; a matrícula conta onde fica a escola, e a população, onde mora a criança.

De volta à pergunta: e se fosse o seu filho?

CENÁRIO HIPOTÉTICO

1. A prefeitura abre vagas de creche onde a fila resiste, como no Tremembé.
2. A criança sai da fila e vira uma linha do fato Matrícula.
3. A família volta a trabalhar com o filho na creche.

O QUE A PROPOSTA ENTREGA

Uma consulta no lugar de três bases
fila, matrícula, ocupação e população lado a lado, por distrito

Respostas em menos de um segundo
as oito consultas rodam em 0,42 s sobre os dados reais

Números conferidos
14 verificações a cada carga e a contagem em dobro à vista

Dez anos de histórico
onde a fila caiu e onde ela resiste

Cada vaga aberta no lugar certo é uma criança a menos na fila.

Cenário hipotético. Números reais das consultas 5, 7 e 8 e da nossa carga.

Obrigado. Perguntas?

13,4 mi
matrículas de 2015 a 2024

551 mil
turmas carregadas

26.889
setores censitários

- Relatório: descrição do problema, povoamento atributo por atributo, cinco estrelas, constelação e oito consultas.
- Repositório: pipeline do portal ao DuckDB, 14 verificações de qualidade e testes automáticos, inclusive da modelagem.
- Carga real: 13,4 milhões de matrículas, 551 mil turmas e 26.889 setores censitários em 3,5 minutos, sem nenhuma FALHA nas verificações.

github.com/kevennlaranjeira/OLAP2026

Kevenn Laranjeira de Oliveira · Thiago Rodrigues Gouveia da Silva · Daniel Afonso Borges dos Santos · Luís Antônio Arruda Soares