SCC0245 · PROCESSAMENTO ANALÍTICO DE DADOS · PROJETO 1

Rede Municipal Paulistana: oferta escolar e demanda não atendida

Um data warehouse para decidir onde abrir vagas, com dados abertos da SME-SP e do IBGE

Profa. Dra. Cristina Dutra de Aguiar · ICMC-USP, São Carlos

GRUPO 7

Kevenn Laranjeira de Oliveira · Nº USP 18046529
Thiago Rodrigues Gouveia da Silva · Nº USP 18066911
Daniel Afonso Borges dos Santos · Nº USP 12608581
Luís Antônio Arruda Soares · Nº USP 12559486

13,4 mi
matrículas de 2015 a 2024

44
meses de fila por distrito

26.889
setores censitários do Censo 2022

Em dez anos, a fila de creche caiu 97%

A falta de vaga em creche foi por anos o principal problema de acesso da educação infantil em São Paulo.

PNE (Lei 13.005/2014), Meta 1: creche para ao menos metade das crianças de até 3 anos; pré-escola universal.

A cidade avançou: a demanda de creche fora da rede passou de 34% para 1%.

Fonte: Demanda Registrada e Matrículas (SME-SP); consulta 5 sobre a carga com os dados reais.

FILA DE CRECHE EM JUNHO

2015

124.741

crianças · 34% da demanda fora da rede

-97%

2024

3.633

crianças · 1% da demanda fora da rede

E se fosse o seu filho?

3.633

crianças ainda esperavam vaga em creche em junho de 2024, em todos os 96 distritos

SEU FILHO

Meses fora da creche. Poderia chegar à escola atrás das crianças que tiveram educação infantil.

SEU TRABALHO

Faltas, um cuidador pago ou o emprego deixado de lado até a vaga sair.

SUA CASA

Avós, vizinhos e irmãos mais velhos cobrindo o horário da creche.

A fila caiu 97%. Para essas famílias, a espera continua.

Fonte: Demanda Registrada e Matrículas (SME-SP), junho de 2024. As consequências são um cenário ilustrativo.

O problema: saber onde abrir a próxima vaga

Quem aceita qualquer unidade não espera muito: em junho de 2024, nenhuma criança desse grupo estava na fila havia mais de 30 dias.

Quase sete em cada dez crianças da fila esperavam uma unidade específica, escolhida pela família.

A fila está nos 96 distritos, e a oferta vai de menos de 50 a mais de 100 matrículas por 100 crianças (Censo 2022).

Fonte: Demanda Registrada e Matrículas (SME-SP), junho de 2024, no fato Fila; Censo 2022 (IBGE), consulta 7.

FILA DE CRECHE, JUNHO DE 2024

3.633

crianças esperando vaga

2.502 esperavam uma unidade específica, escolhida pela família

1.131 aceitavam qualquer unidade; nenhuma esperava havia mais de 30 dias

Hoje, os dados se repetem e não conversam

1 Matrícula contada em dobro

Junho de 2022: 378.954 matrículas de creche ativas no microdado, mas 340.085 alunos.

A rede parece atender 38.869 crianças a mais.

2 Escolas diferentes, um código só

2024: 193 códigos para 4.011 escolas, em notação científica.

Não dá para saber em qual escola está a vaga.

3 Totais que não fecham

Fila de junho de 2023: a soma dos distritos dá 2.926 crianças com opção; o total publicado, 2.904.

Cada área pode chegar a um número diferente.

4 Zero que não é zero

Até setembro de 2020, a fila não separava quem esperava havia mais de 30 dias.

Gravar zero faria essa espera sumir.

Fonte: nossa carga com os dados reais da SME-SP; o tratamento de cada caso está em docs/04 e no bloco 2.

Nossa solução: as três bases num data warehouse

HOJE

Três bases que não conversam

- **Fila:** planilha por distrito, publicada em sete formatos diferentes.
- **Matrícula:** 13,4 milhões de linhas; de 2022 a 2024 o código da escola chega corrompido.
- **População:** Censo do IBGE, por setor censitário e em faixas de cinco anos.
- Nem o distrito é escrito igual: AGUA RASA na SME, Água Rasa no IBGE.

COM O NOSSO DATA WAREHOUSE

Uma pergunta, uma consulta

- Um comando baixa, limpa, carrega e confere os dados do portal da prefeitura e do IBGE.
- Cinco fatos e catorze dimensões que se cruzam por distrito, etapa e data.
- 14 verificações de qualidade a cada carga; na carga real, nenhuma deu FALHA.
- Oito consultas OLAP respondem às perguntas do gestor.

Quem usa: a Secretaria Municipal de Educação e as 13 Diretorias Regionais, para decidir onde abrir a próxima vaga.

Consultas mais confiáveis e mais rápidas

MAIS RÁPIDA

0,42 s

para as oito consultas OLAP, somadas, sobre 13,4 milhões de matrículas

MAIS RÁPIDA

3,5 min

para carregar tudo no banco, com um comando

MAIS CONFIÁVEL

14

verificações a cada carga; nenhuma FALHA na carga real

MAIS CONFIÁVEL

< 1%

de diferença entre as bases da SME de 2015 a 2020; depois, a diferença fica à vista

Uma linguagem só

Distrito, etapa e idade com a mesma representação nas três bases; nulo quer dizer não publicado, nunca zero; a contagem em dobro do microdado fica ao lado da matrícula da planilha. A Secretaria e as 13 Diretorias olham o mesmo número.

Do dado à vaga: como a fila pode cair mais

1. Medir

A fila de cada distrito e etapa, a cada publicação, separando quem espera uma unidade específica.

fato Fila

2. Localizar

Onde a fila resiste e onde a oferta por criança é menor.

C1 C5 C7

3. Decidir

Turma nova ou lugar ocioso, pela ocupação das turmas, e por qual rede abrir a vaga.

C3 C4 C8

4. Acompanhar

A publicação seguinte mostra se a fila do distrito caiu; o ciclo recomeça.

C1 C5

Quase sete em cada dez crianças da fila de creche esperavam uma unidade específica: falta vaga no lugar certo, e é isso que o ciclo procura.

Por que São Paulo, e não São Carlos

PRIMEIRA PROPOSTA

São Carlos

Oferta escolar por setor censitário. Sem dado aberto de vaga nem de fila, a demanda não atendida teria de ser estimada.

ESCOLHA

São Paulo

A SME publica o microdado de cada matrícula e a fila de espera por distrito: demanda medida, não estimada. 13,4 milhões de matrículas de 2015 a 2024.

O modelo vale para São Carlos: matrícula, turma e desfecho vêm do registro que todo sistema de gestão escolar mantém, e o Censo 2022 já tem a população por setor censitário do município. Falta só a rede registrar e publicar a fila.

Cinco assuntos de interesse e por que importam

Matrículas

oferta efetivamente usada, com o perfil de cada aluno

fato Matrícula

Fila (demanda registrada)

quem pediu vaga e não foi atendido

fato Fila

Capacidade e ocupação das turmas

se a oferta existente está cheia: turma nova ou lugar ocioso

fato Ocupação de Turma

População em idade escolar

demanda potencial, mesmo sem pedido de vaga

fato População

Oferta escolar por setor

onde e por qual rede (direta ou conveniada) a vaga é oferecida

dimensões Escola, Território e Setor

Quinto processo: desfecho da matrícula. Acompanha o que acontece depois do acesso: aprovação, reprovação, abandono e transferência.

Imagine que a prefeitura adote a nossa proposta

1

Kevenn Laranjeira de Oliveira

Slides 1 a 11

O problema e a proposta

A fila que ainda existe, a proposta, os ganhos, São Paulo e os assuntos.

2

Thiago Rodrigues Gouveia da Silva

Slides 12 a 16

Passo 1: os dados

Fontes, integração, problemas nos dados, grão e a estrela Matrícula.

3

Daniel Afonso Borges dos Santos

Slides 17 a 21

Passo 2: o modelo

Estrelas Fila, Desfecho, Ocupação de Turma e População; constelação.

4

Luís Antônio Arruda Soares

Slides 22 a 28

Passo 3: as respostas

Consultas, resultados, decisões e um exemplo de onde abrir vaga.



A adoção é um cenário hipotético; os números vêm da nossa carga com os dados reais.

Três fontes, três perguntas sobre cada distrito

SME-SP · ANUAL

Quem já tem vaga?

Microdados de Matrículas

13,4 mi

matrículas, 2015 a 2024

UMA LINHA É

um aluno numa turma, num ano letivo

SME-SP · TRIMESTRAL E BIMESTRAL

Quem espera vaga?

Demanda Registrada e Matrículas

44 meses

de fila, 96 distritos em cada mês

UMA LINHA É

um distrito num mês, com uma coluna por etapa

IBGE · CENSO 2022

Quantas crianças moram ali?

Agregados por Setores Censitários

26.889

setores, 11,4 milhões de moradores

UMA LINHA É

um setor censitário, com uma coluna por faixa de idade

O exemplo que vamos seguir: o Tremembé. Em junho de 2024, **153** crianças esperavam creche lá; o Censo conta **11.498** crianças de 0 a 4 anos morando no distrito; e cada matrícula das escolas do distrito é uma linha do microdado.

Integração: o mesmo dado, escrito de jeitos diferentes

COMO CHEGA	REGRA	NO DATA WAREHOUSE
Distrito fila: `TREMEMBE` (matrícula: `TREMEMBE`, IBGE: `Tremembé`)	→ maiúsculas, sem acento, sem espaço sobrando	→ **TREMEMBE**: uma única linha da dimensão Território
Idade matrícula: idade exata `2 anos`; IBGE: só o grupo `0 a 4 anos`	→ cada idade ganha a faixa do IBGE em que cai	→ matrícula e população comparadas na **mesma faixa**, 0 a 4 anos
Setor SME: setor administrativo `CD_SETOR, 4 dígitos`; IBGE: setor censitário `CD_SETOR, 15 dígitos`	→ mesmo nome, coisas diferentes: um **homônimo**	→ dois atributos com nomes distintos, **nunca cruzados**

< 1%

Como sabemos que deu certo? Contamos a mesma coisa nas duas bases da SME: as matrículas de creche ativas em junho de 2015 foram **240.905** no microdado e **240.840** na planilha da fila. De 2015 a 2020 a diferença fica abaixo de 1%.

Problemas reais nos dados: o que fizemos e por quê

Problema	Como chegou	O que fizemos	Por que importa
1 **Código da escola**	2022: embaralhado. 2023 e 2024: `9,20961E+15` ; em 2023, 182 códigos para 3.858 escolas	Medimos cada ano no próprio dado (notação científica? código repetido?). Nos anos ruins, achamos a mesma escola pelo **nome, tipo e distrito** no último ano confiável e copiamos o código de lá. Sem par seguro, chave sintética, nunca um chute.	**94,8% a 98,6%** das matrículas ligadas ao código real; sem isso, centenas de escolas virariam uma só.
2 **Planilha de fila em sete formatos**	a coluna `(2)` é “preferiu esperar uma unidade” em 2019 e “mais de 30 dias” desde 2020	Lemos o cabeçalho e as notas de rodapé de cada arquivo e traduzimos cada nota. Nota desconhecida **para a carga**, em vez de gravar o número.	Nenhum número da fila entra com o sentido trocado.
3 **Turno não publicado em 2021**	só o código `9` , sem descrição	Descobrimos que o código de 2021 é o de 2020 somado de 3 e conferimos pelos horários: 9 é integral, das 7h às 17h. Sem código, o turno sai do horário da turma.	Turno e jornada comparáveis em todos os anos.
4 **Idade em formato errado**	`5,00` , vazia, ou nascimento em 1900 (115 a 124 anos)	Usamos a idade publicada se for plausível; senão, calculamos pela data de nascimento, em 31 de março. Nascimento em 1900 vira **não informada**.	Sem isso, a faixa de 0 a 4 anos comparada com o Censo sairia errada.
5 **Datas em cinco formatos**	`45397` (serial do Excel) e outros quatro formatos	Lemos todos. O serial conta dias desde 30/12/1899: 45397 é 15/04/2024. Data fora de um ano em volta do ano letivo é descartada.	As datas dizem quem estava matriculado em 30 de junho, o número que se compara com a fila.
6 **Valores suprimidos pelo IBGE**	`X` no lugar do número, em setores pequenos	Só aceitamos números; o X vira **nulo**. Foram **6.543** valores. Se a maioria não fosse número, a leitura pararia.	Nulo é “não publicado”; zero seria “nenhuma criança”, o que é falso.

Grão: o que é uma linha. Aditividade: o que soma.

GRÃO = O QUE UMA LINHA REPRESENTA

fato Fila

TREMEMBE	jun/2024	CRECHE	153

fato Matrícula

um aluno	uma turma	2024	1

Uma criança não é uma linha da fila: **é uma das 153**. Quando consegue a vaga, vira uma linha do fato Matrícula.

ADITIVIDADE = POSSO SOMAR?

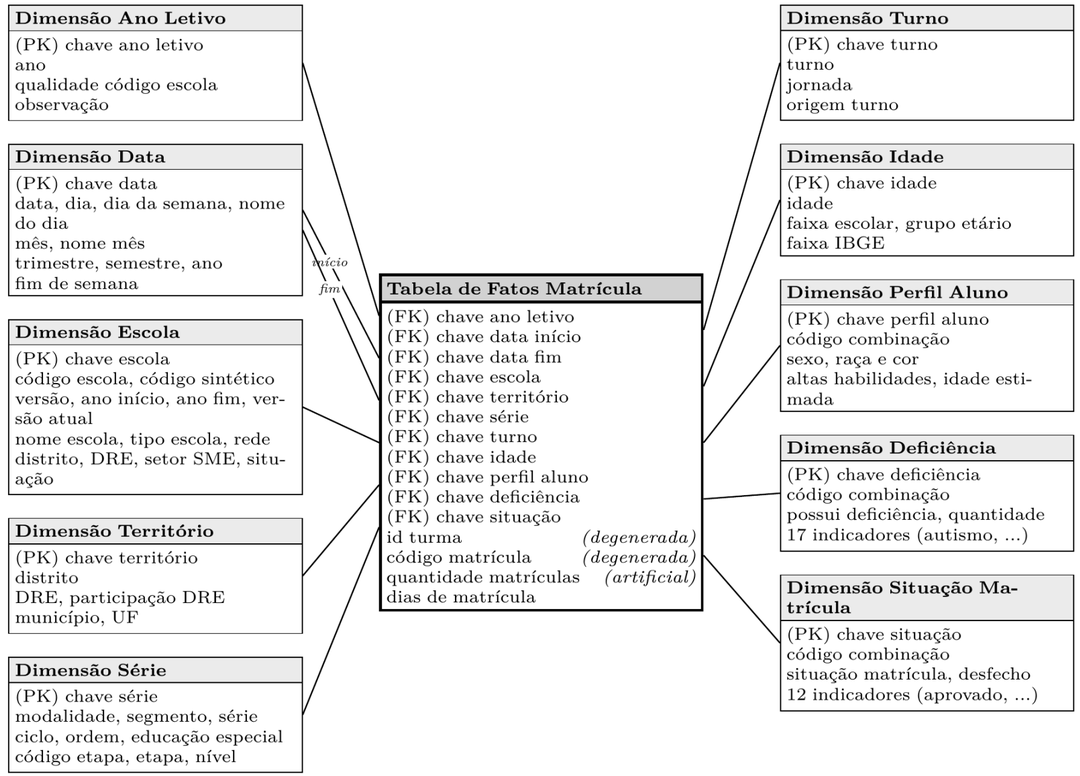
✓ **Somar distritos:** Tremembé + Grajaú em junho de 2024 = 153 + 88 = 241 crianças na fila.

✗ **Somar meses:** fila de abril + fila de junho conta duas vezes quem continuou esperando. A fila é um **estoque**.

÷ **Taxas e médias:** nunca somar nem tirar média; recalcular das somas (abandonos ÷ matrículas).

Tabela de fatos	Uma linha é	Pode somar?
Matrícula	um vínculo aluno-turma × ano	**aditivo**: soma em tudo
Fila	distrito × mês × etapa	**semiaditivo**: soma distritos e etapas, não meses
Desfecho	escola × ano × série	**aditivo** nas contagens; taxas recalculadas
Ocupação de Turma	turma × ano	**aditivo** nas contagens; alunos por turma recalculado
População	setor censitário × faixa × Censo	**semiaditivo**: soma setores e faixas, não Censos

Esquema estrela Matrícula



CADA RECURSO RESOLVE UM PROBLEMA

1. **Data com dois papéis** (início e fim): diz se a matrícula estava ativa em 30 de junho, o número que se compara com a fila.
2. **Campo igual a 1** em cada linha: contar matrículas vira uma soma. Dias de matrícula é a outra medida.
3. **Bugigangas** (Perfil, Deficiência, Situação): mais de 30 indicadores em 3 dimensões, e não em 30.
4. **Degeneradas** (id da turma, código da matrícula): identificadores que ficam no fato, sem tabela própria.
5. **Escola tipo 2**: a escola que muda de nome ganha uma versão nova, e a matrícula antiga guarda o nome da época.

Esquema estrela Fila



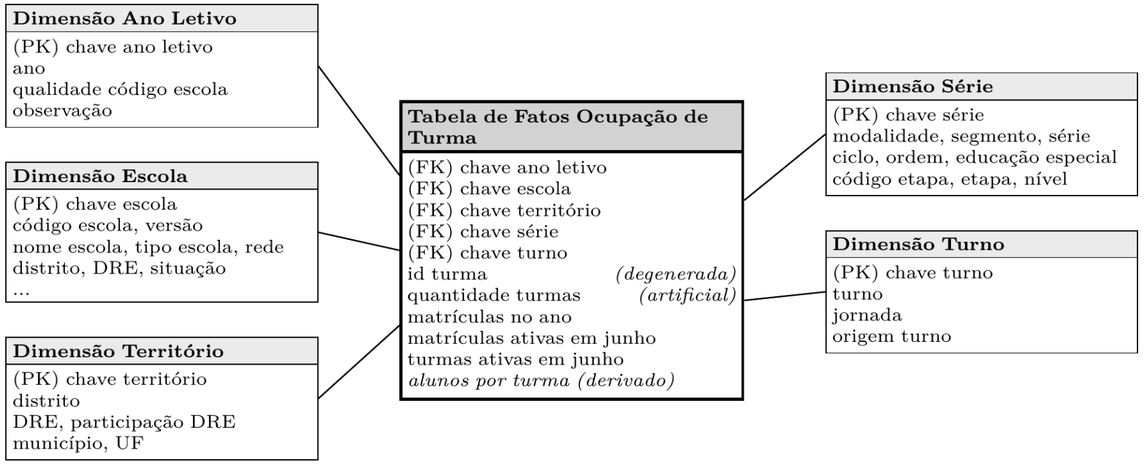
- Grão: distrito × mês × etapa.
- Estoque: SOMA no território e na etapa; um único mês no tempo.
- Formato da planilha: dimensão degenerada.
- Tempo: mês ≤ trimestre ≤ semestre ≤ ano e mês ≤ bimestre ≤ ano.
- Território: distrito ≤ DRE ≤ município ≤ UF.

Esquema estrela Desfecho



- Grão: escola × ano letivo × série.
- Fato agregado do fato Matrícula.
- Contagens por desfecho: SOMA.
- Taxas derivadas, não aditivas: recalculadas pelas contagens.
- Série: série ≤ etapa ≤ nível.

Esquema estrela Ocupação de Turma



- Grão: turma × ano letivo.
- Turmas (= 1), matrículas e ativas em 30/06: SOMA.
- Alunos por turma: derivado, recalculado pelas somas.
- Capacidade não publicada por nenhuma fonte: não é estimada.
- id turma: dimensão degenerada.

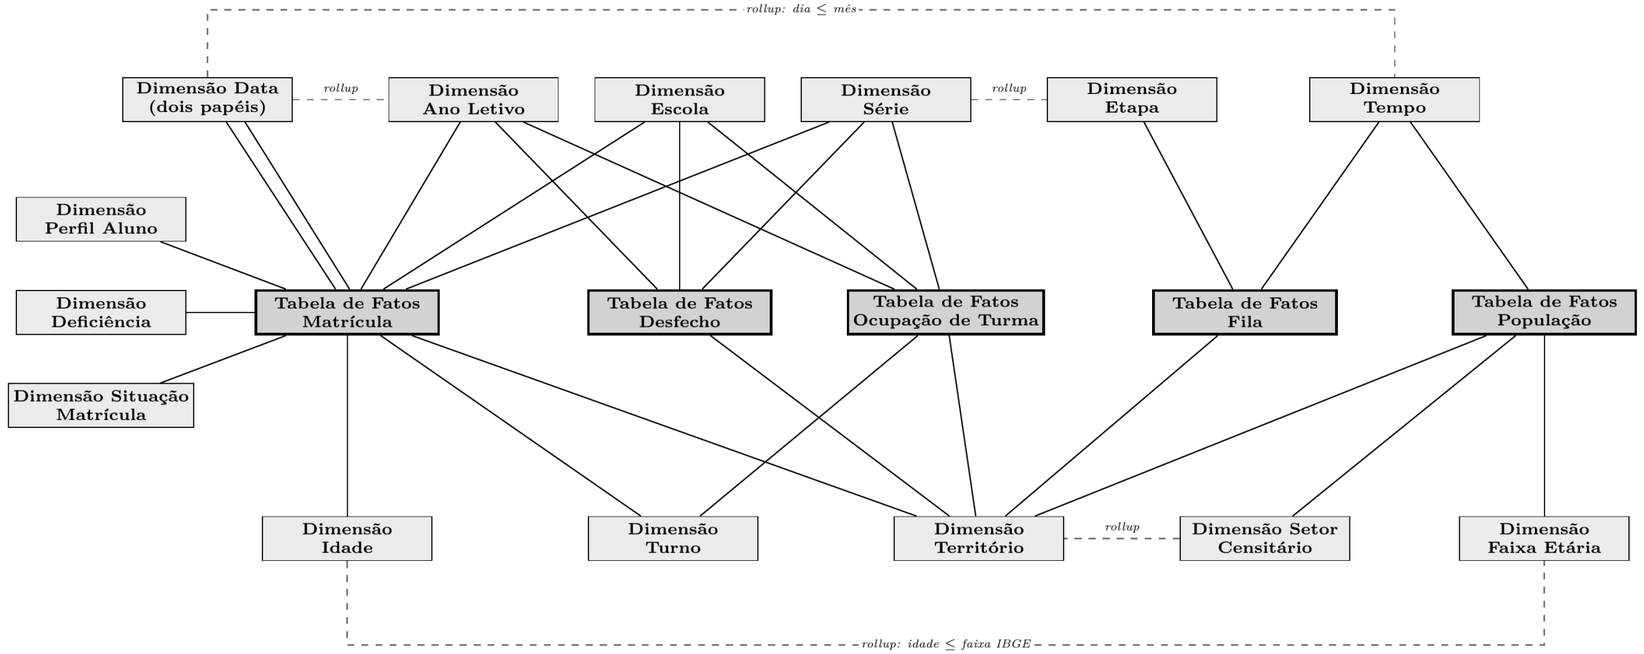
Esquema estrela População



- Grão: setor censitário × faixa etária × data do Censo.
- Estoque: SOMA entre setores e faixas, não no tempo.
- Valor suprimido pelo IBGE fica nulo.
- Setor censitário ≤ distrito ≤ DRE ≤ município ≤ UF.
- Faixa Etária: rollup encolhido de Idade.

Constelação de fatos

5 fatos | 14 dimensões | Território nos cinco fatos



Processo de projeto: matriz de barramento (fato × dimensão), dimensões conformadas e, onde os grãos diferem, rollups encolhidos (tracejado).

Oito consultas OLAP

Exigido: 2 roll-up ou drill-down, 1 slice and dice, 1 pivot, 1 drill-across.
Feito: 3, 1, 1 e 3.

C1 drill-down

Fila de creche: município → DRE → distrito

528 crianças

em dez/2024; Ipiranga lidera (103)

Fila

C2 roll-up

Matrículas: etapa → nível → total, ano a ano

1,42 milhão

de matrículas em 2024; creche +48% desde 2015

Matrícula

C3 slice and dice

Creche por rede e jornada, 2019 e 2024

85% conveniada

e quase toda em jornada integral, nos dois anos

Matrícula

C4 pivot

DRE nas linhas, jornada nas colunas

35,5% a 47,2%

em jornada integral, por DRE (2024)

Matrícula

C5 drill-across

Fila contra matrícula ativa em junho, por distrito

-97%

na fila de creche em junho, de 2015 a 2024

Fila e Matrícula

C6 drill-across

Fila de creche e abandono no fundamental, por DRE

-0,27 a 0,56

correlação nas 13 DREs; o sinal muda entre os anos

Fila, Matrícula e Desfecho

C7 drill-across

0 a 4 anos: residentes, matriculadas e na fila

86 por 100

matrículas por 100 crianças residentes (31/07/2022)

População, Matrícula e Fila

C8 drill-down

Alunos por turma: município → DRE → distrito

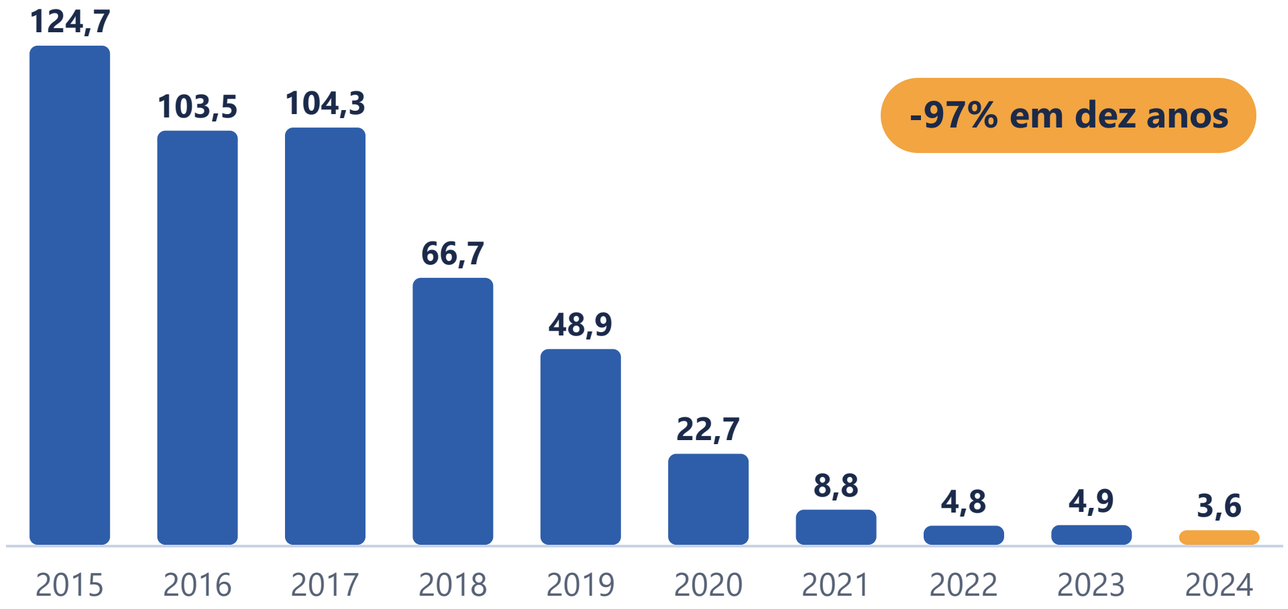
11 por turma

na creche; de 28,7 a 31,6 no fundamental

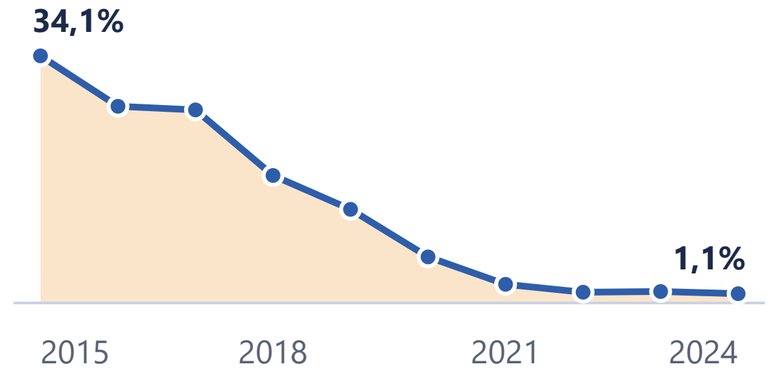
Ocupação de Turma

Resultados: fila e oferta de creche

Crianças na fila de creche em junho, em milhares (consulta 5)



Fração da demanda de creche fora da rede



85% da creche é conveniada, quase toda em jornada integral, em 2019 e em 2024 (consulta 3).

Fonte: SME-SP, Demanda Registrada e Matrículas e Microdados de Matrículas; consultas 3 e 5.

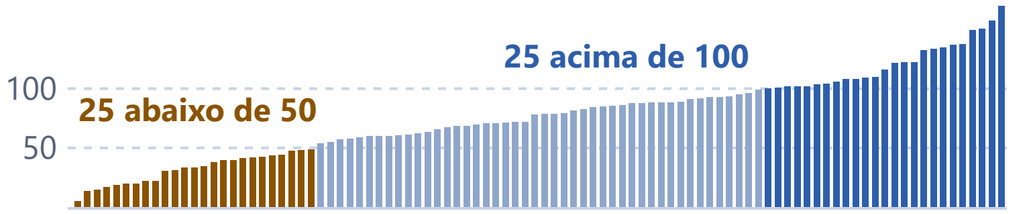
Resultados: população e ocupação das turmas

CONSULTA 7 · 31/07/2022

86 **matrículas por 100 crianças de 0 a 4 anos**

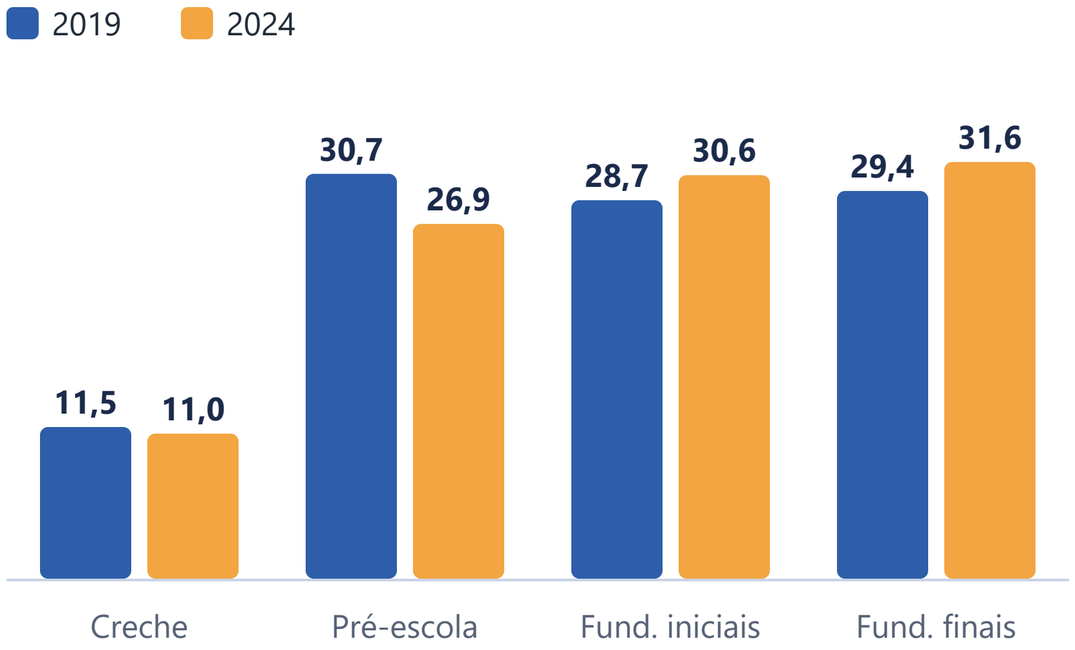
514.131 matrículas ativas para 598.406 crianças residentes.

Por distrito, longe da média (96 distritos)



Extremos: Jardim Paulista (4,7) e Lajeado (169,7). A matrícula conta onde a escola fica.

Alunos por turma em 30 de junho (consulta 8)



Fonte: Censo 2022 (IBGE) e Microdados de Matrículas (SME-SP); consultas 7 e 8.

Decisões de projeto em destaque

1 **Grão mais fino na matrícula**

vínculo aluno-turma: preserva perfil e desfecho de cada aluno

2 **Rollups encolhidos**

cada fato mantém o seu grão; Etapa, Tempo, Faixa Etária e Território conformam

3 **Nulo não é zero**

medida não publicada fica nula; zero faria a fila sumir

4 **Escola tipo 2**

402 escolas mudam de nome, tipo, distrito ou DRE na série

5 **Capacidade não inventada**

ocupação medida pelos alunos ativos; nenhuma vaga estimada

6 **Datas de referência**

junho para fila × matrícula; 31/07/2022 para população × matrícula

Um exemplo: a próxima vaga vai para o Tremembé

GRAJAÚ · O MAIOR DISTRITO

24.398 crianças de 0 a 4 anos (Censo 2022)

82,7 matrículas por 100 crianças (2022)

88 na fila de creche em junho de 2024; eram 8.018 em 2015

TREMEMBÉ

11.498 crianças de 0 a 4 anos (Censo 2022)

71,6 matrículas por 100 crianças, abaixo da média de 86

153 na fila de creche em junho de 2024, a segunda maior da cidade

O que o cruzamento mostra: pelo tamanho, a escolha seria o Grajaú; com fila, oferta e população lado a lado, a próxima vaga pesa mais no Tremembé.

Fonte: consultas 5 e 7; a matrícula conta onde fica a escola, e a população, onde mora a criança.

De volta à pergunta: e se fosse o seu filho?

CENÁRIO HIPOTÉTICO

1. A prefeitura abre vagas de creche onde a fila resiste, como no Tremembé.
2. A criança sai da fila e vira uma linha do fato Matrícula.
3. A família volta a trabalhar com o filho na creche.

O QUE A PROPOSTA ENTREGA

Uma consulta no lugar de três bases
fila, matrícula, ocupação e população lado a lado, por distrito

Respostas em menos de um segundo
as oito consultas rodam em 0,42 s sobre os dados reais

Números conferidos
14 verificações a cada carga e a contagem em dobro à vista

Dez anos de histórico
onde a fila caiu e onde ela resiste

Cada vaga aberta no lugar certo é uma criança a menos na fila.

Cenário hipotético. Números reais das consultas 5, 7 e 8 e da nossa carga.

Obrigado. Perguntas?

13,4 mi
matrículas de 2015 a 2024

551 mil
turmas carregadas

26.889
setores censitários

- Relatório: descrição do problema, povoamento atributo por atributo, cinco estrelas, constelação e oito consultas.
- Repositório: pipeline do portal ao DuckDB, 14 verificações de qualidade e testes automáticos, inclusive da modelagem.
- Carga real: 13,4 milhões de matrículas, 551 mil turmas e 26.889 setores censitários em 3,5 minutos, sem nenhuma FALHA nas verificações.

github.com/kevennlaranjeira/OLAP2026

Kevenn Laranjeira de Oliveira · Thiago Rodrigues Gouveia da Silva · Daniel Afonso Borges dos Santos · Luís Antônio Arruda Soares