SCC0245 · PROCESSAMENTO ANALÍTICO DE DADOS · PROJETO 1

Rede Municipal Paulistana: oferta escolar e demanda não atendida

Um data warehouse para decidir onde abrir vagas, com dados abertos da SME-SP e do IBGE

Profa. Dra. Cristina Dutra de Aguiar · ICMC-USP, São Carlos

GRUPO 7

Kevenn Laranjeira de Oliveira · Nº USP 18046529
Thiago Rodrigues Gouveia da Silva · Nº USP 18066911
Daniel Afonso Borges dos Santos · Nº USP 12608581
Luís Antônio Arruda Soares · Nº USP 12559486

13,4 mi
matrículas de 2015 a 2024

44
meses de fila por distrito

26.889
setores censitários do Censo 2022

A Ana tem 1 ano e está na fila da creche

PERSONA HIPOTÉTICA

Ana, 1 ano

mora no Tremembé, DRE Jaçanã/Tremembé

A MÃE

Precisa voltar a trabalhar e não tem com quem deixar a filha. A vaga que apareceu ficava longe de casa, e ela decidiu esperar a creche do bairro.

A ANA

Fica fora da creche enquanto espera. Cada mês na fila é um mês a menos de creche.

O TREMEMBÉ NOS NOSSOS DADOS

153 na fila de creche do Tremembé em junho de 2024, a segunda maior da cidade

74 delas esperavam uma unidade específica, como a mãe da Ana

2,5% da demanda de creche fora da rede, mais que o dobro da cidade (1,1%)

Persona hipotética. Números reais do Tremembé: Demanda Registrada e Matrículas (SME-SP), junho de 2024.

E se fosse o seu filho?

3.633

crianças esperavam vaga em creche em São Paulo em junho de 2024

2.502

esperavam uma vaga numa unidade específica, escolhida pela família

1.131

aceitavam qualquer unidade e esperavam havia até 30 dias

A fila caiu 97% desde 2015. Para essas famílias, a espera continua.

Fonte: Demanda Registrada e Matrículas (SME-SP), junho de 2024, no fato Fila.

O problema: saber onde abrir a próxima vaga

A falta de vaga em creche foi por anos o principal problema de acesso da educação infantil em São Paulo.

PNE (Lei 13.005/2014), Meta 1: creche para ao menos metade das crianças de até 3 anos; pré-escola universal.

Em 2024 ainda havia fila nos 96 distritos. No Censo 2022, a oferta ia de menos de 50 a mais de 100 matrículas por 100 crianças.

Fonte: Demanda Registrada e Matrículas (SME-SP) e Censo 2022 (IBGE); consultas 5 e 7.

FILA DE CRECHE EM JUNHO

2015

124.741

crianças · 34% da demanda fora da rede

-97%

2024

3.633

crianças · 1% da demanda fora da rede

Nossa solução: as três bases num data warehouse

HOJE

Três bases que não conversam

- **Fila:** planilha por distrito, publicada em sete formatos diferentes.
- **Matrícula:** 13,4 milhões de linhas; de 2022 a 2024 o código da escola chega corrompido.
- **População:** Censo do IBGE, por setor censitário e em faixas de cinco anos.
- Nem o distrito é escrito igual: AGUA RASA na SME, Água Rasa no IBGE.

COM O NOSSO DATA WAREHOUSE

Uma pergunta, uma consulta

- Um comando baixa, limpa, carrega e confere os dados do portal da prefeitura e do IBGE.
- Cinco fatos e catorze dimensões que se cruzam por distrito, etapa e data.
- 14 verificações de qualidade a cada carga; na carga real, nenhuma deu FALHA.
- Oito consultas OLAP respondem às perguntas do gestor.

Quem usa: a Secretaria Municipal de Educação e as 13 Diretorias Regionais, para decidir onde abrir a próxima vaga.

Do dado à vaga: como a fila pode cair mais

1. Medir

A fila de cada distrito e etapa, a cada publicação, separando quem espera uma unidade específica.

fato Fila

2. Localizar

Onde a fila resiste e onde a oferta por criança é menor.

C1 C5 C7

3. Decidir

Turma nova ou lugar ocioso, pela ocupação das turmas, e por qual rede abrir a vaga.

C3 C4 C8

4. Acompanhar

A publicação seguinte mostra se a fila do distrito caiu; o ciclo recomeça.

C1 C5

Quase sete em cada dez crianças da fila de creche esperavam uma unidade específica: falta vaga no lugar certo, e é isso que o ciclo procura.

Por que São Paulo, e não São Carlos

PRIMEIRA PROPOSTA

São Carlos

Oferta escolar por setor censitário. Sem dado aberto de vaga nem de fila, a demanda não atendida teria de ser estimada.

ESCOLHA

São Paulo

A SME publica o microdado de cada matrícula e a fila de espera por distrito: demanda medida, não estimada. 13,4 milhões de matrículas de 2015 a 2024.

O modelo vale para São Carlos: matrícula, turma e desfecho vêm do registro que todo sistema de gestão escolar mantém, e o Censo 2022 já tem a população por setor censitário do município. Falta só a rede registrar e publicar a fila.

Cinco assuntos de interesse e por que importam

Matrículas

oferta efetivamente usada, com o perfil de cada aluno

fato Matrícula

Fila (demanda registrada)

quem pediu vaga e não foi atendido

fato Fila

Capacidade e ocupação das turmas

se a oferta existente está cheia: turma nova ou lugar ocioso

fato Ocupação de Turma

População em idade escolar

demanda potencial, mesmo sem pedido de vaga

fato População

Oferta escolar por setor

onde e por qual rede (direta ou conveniada) a vaga é oferecida

dimensões Escola, Território e Setor

Quinto processo: desfecho da matrícula. Acompanha o que acontece depois do acesso: aprovação, reprovação, abandono e transferência.

Imagine que a prefeitura adote a nossa proposta

1

Kevenn Laranjeira de Oliveira

Slides 1 a 9

O problema e a proposta

A Ana, o problema, a proposta, o ciclo, São Paulo e os assuntos.

2

Thiago Rodrigues Gouveia da Silva

Slides 10 a 14

Passo 1: os dados

Fontes, integração, problemas nos dados, grão e a estrela Matrícula.

3

Daniel Afonso Borges dos Santos

Slides 15 a 19

Passo 2: o modelo

Estrelas Fila, Desfecho, Ocupação de Turma e População; constelação.

4

Luís Antônio Arruda Soares

Slides 20 a 26

Passo 3: as respostas

Consultas, resultados, decisões e a vaga da Ana.

A história é um cenário hipotético; os números vêm da nossa carga com os dados reais.

Três fontes de dados reais e oficiais

SME-SP · ANUAL

Microdados de Matrículas

13,4 mi

matrículas de escolarização, 2015 a 2024

Uma linha por vínculo aluno-turma: escola, turma, turno, série, idade, perfil, deficiência, datas e desfecho.

SME-SP · TRIMESTRAL E BIMESTRAL

Demanda Registrada e Matrículas

44 meses

33 arquivos × 96 distritos no recorte

Por distrito e etapa: matrículas, matrículas em processo e fila. Trimestral até 2022, bimestral desde 2023; sete formatos diferentes.

IBGE · AGREGADOS POR SETORES

Censo Demográfico 2022

26.889

setores do município, 11,4 milhões de moradores

Pessoas residentes por setor censitário e grupo de idade (variáveis V01031 a V01041); referência 31/07/2022.

Integração: o mesmo dado em formas diferentes

Dado	SME	IBGE	No data warehouse
Distrito	AGUA RASA	Água Rasa + código de 9 dígitos	nome normalizado, chave da dimensão Território
Idade	idade simples em 31/03	grupo de 0 a 4, 5 a 9, ...	faixa IBGE na dimensão Idade
Etapa	Creche, Pré Escola (fila); MODALIDADE (microdado)	não se aplica	catálogo único de etapas
Setor	CD_SETOR: 4 dígitos, administrativo	CD_SETOR: 15 dígitos, censitário	homônimo: nunca cruzados

< 1%

Reconciliação: matrículas ativas em junho no microdado contra a matrícula da planilha de fila, por distrito e etapa. A diferença fica abaixo de 1% de 2015 a 2020 (creche: +0,03% em 2015, +0,17% em 2019).

Problemas reais nos dados e como foram tratados

1 Código da escola corrompido (2022 a 2024)

recuperado pelo nome, tipo e distrito em **94,8% a 98,6%** das matrículas

2 Sete formatos da planilha de fila

colunas lidas do cabeçalho; significado de (1), (2), (3) lido do rodapé

3 Turno não publicado em 2021

deduzido do código da turma, conferido pelos horários

4 Idade com vírgula, nula ou nascida em 1900

recalculada pelo nascimento; impossível vira não informada

5 Datas em cinco formatos, inclusive serial do Excel

todos lidos; fora da janela do ano letivo, descartadas

6 Valores suprimidos pelo IBGE em setores pequenos

6.543 valores ficam nulos, nunca zero

Grão e aditividade dos fatos

Tabela de fatos	Grão	Fatos	Aditividade
Matrícula	vínculo aluno-turma × ano	quantidade (= 1), dias de matrícula	aditivo
Fila	distrito × mês × etapa	matrículas, em processo, demanda e categorias	semiaditivo (estoque)
Desfecho	escola × ano × série	contagens por desfecho; taxas	aditivo; taxas não aditivas
Ocupação de Turma	turma × ano	turmas, matrículas, ativas em junho; alunos por turma	aditivo; média não aditiva
População	setor censitário × faixa × Censo	pessoas	semiaditivo (estoque)

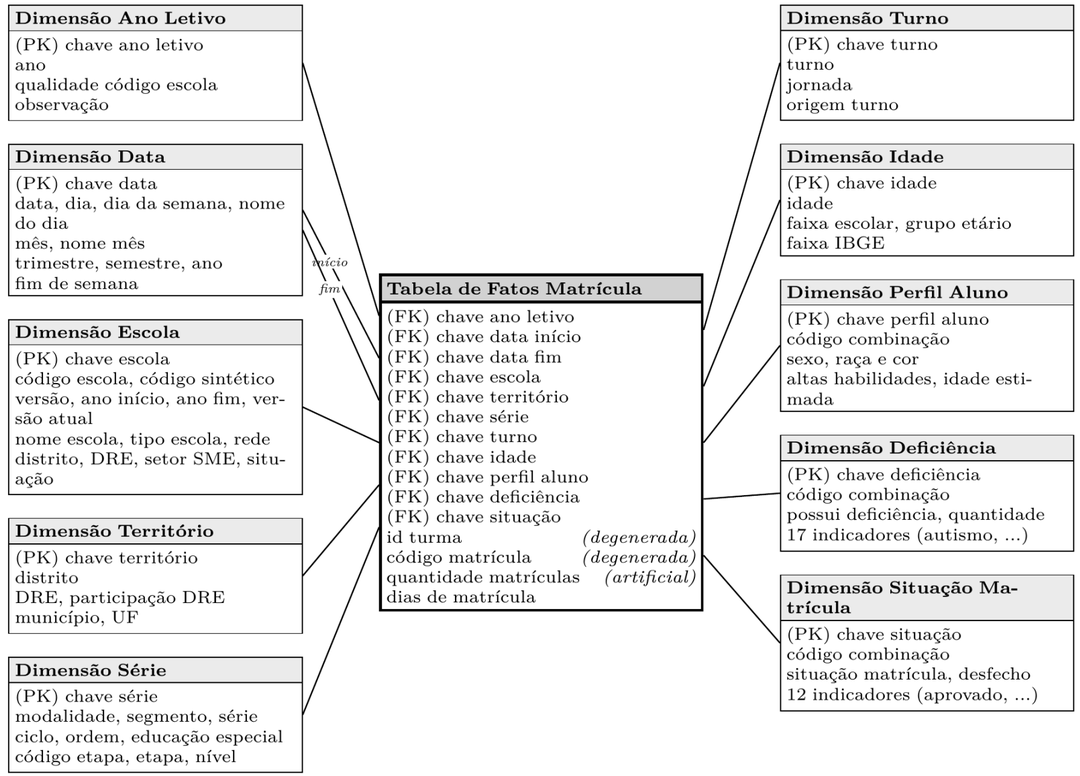
aditivo soma em todas as dimensões

semiaditivo estoque: não soma no tempo

não aditivo recalculado a partir das somas

Fila e população são estoques: somam no território, não no tempo. Taxas e alunos por turma saem sempre das somas.

Esquema estrela Matrícula



LEITURA DO ESQUEMA

- Data com dois papéis: início e fim da matrícula.
- Ocorrência contada por campo artificial (= 1), como em fatos sem fato.
- Bugigangas: Perfil, Deficiência, Situação.
- Degeneradas: id turma, código da matrícula.
- Escola: mudança lenta tipo 2.
- Hierarquias: dia ≤ mês ≤ trimestre ≤ semestre ≤ ano; série ≤ etapa ≤ nível; idade ≤ faixa IBGE.

Esquema estrela Fila



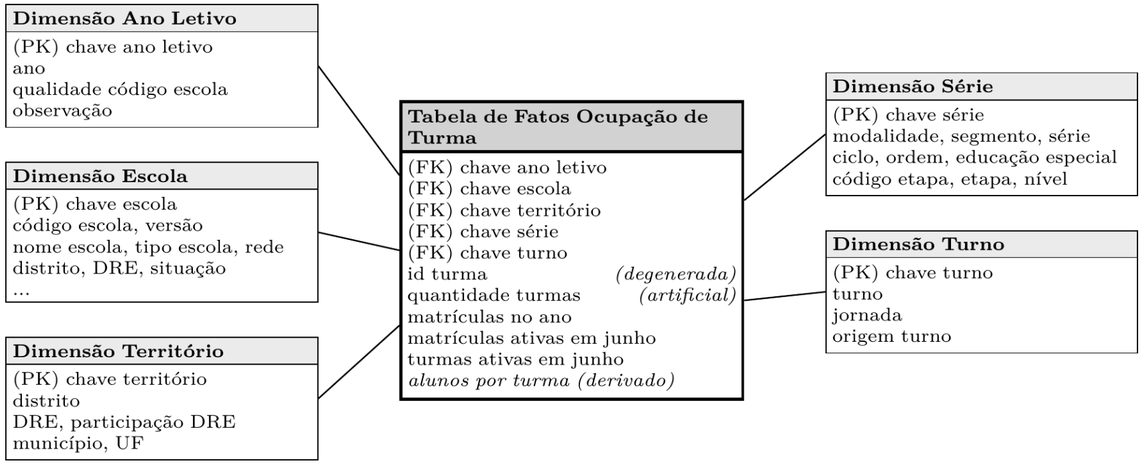
- Grão: distrito × mês × etapa.
- Estoque: SOMA no território e na etapa; um único mês no tempo.
- Formato da planilha: dimensão degenerada.
- Tempo: mês ≤ trimestre ≤ semestre ≤ ano e mês ≤ bimestre ≤ ano.
- Território: distrito ≤ DRE ≤ município ≤ UF.

Esquema estrela Desfecho



- Grão: escola × ano letivo × série.
- Fato agregado do fato Matrícula.
- Contagens por desfecho: SOMA.
- Taxas derivadas, não aditivas: recalculadas pelas contagens.
- Série: série ≤ etapa ≤ nível.

Esquema estrela Ocupação de Turma



- Grão: turma × ano letivo.
- Turmas (= 1), matrículas e ativas em 30/06: SOMA.
- Alunos por turma: derivado, recalculado pelas somas.
- Capacidade não publicada por nenhuma fonte: não é estimada.
- id turma: dimensão degenerada.

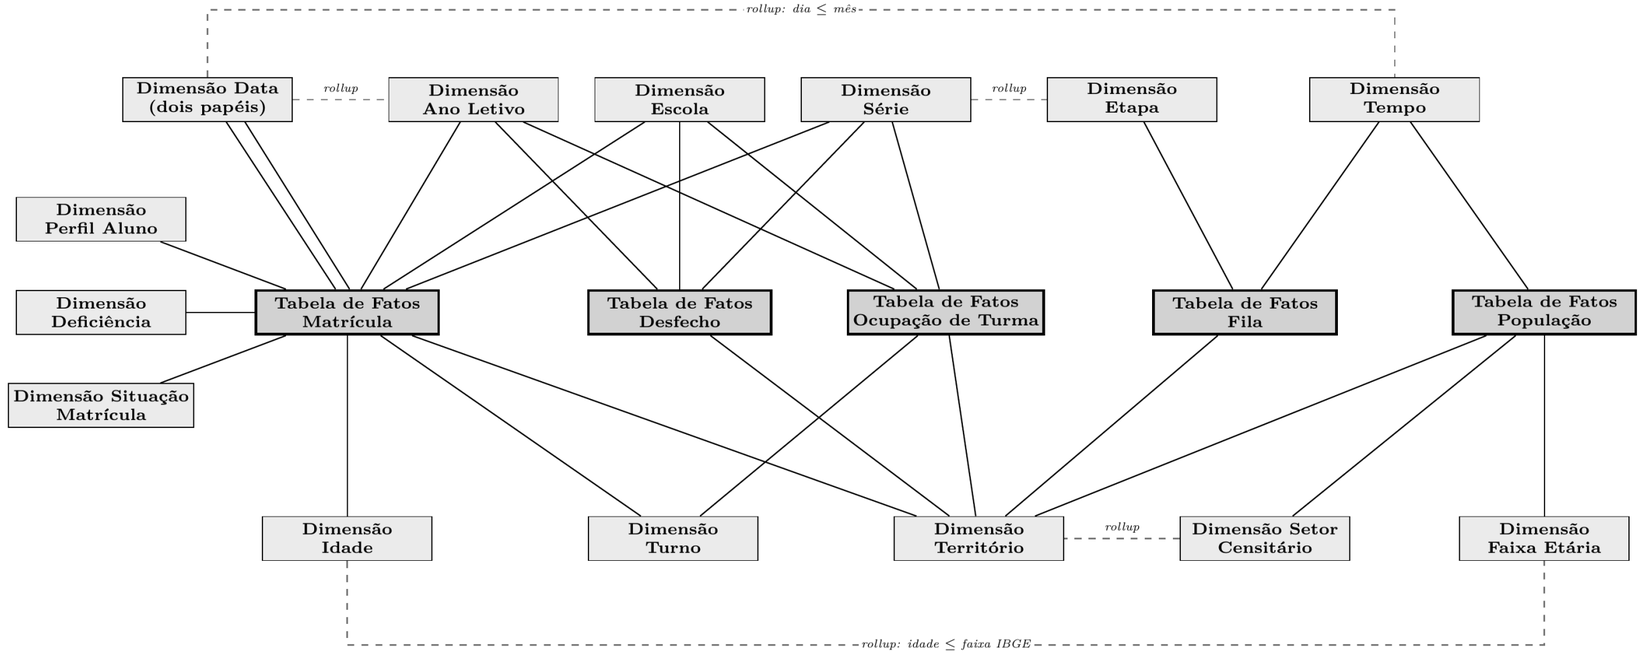
Esquema estrela População



- Grão: setor censitário × faixa etária × data do Censo.
- Estoque: SOMA entre setores e faixas, não no tempo.
- Valor suprimido pelo IBGE fica nulo.
- Setor censitário ≤ distrito ≤ DRE ≤ município ≤ UF.
- Faixa Etária: rollup encolhido de Idade.

Constelação de fatos

5 fatos | 14 dimensões | Território nos cinco fatos



Processo de projeto: matriz de barramento (fato × dimensão), dimensões conformadas e, onde os grãos diferem, rollups encolhidos (tracejado).

Oito consultas OLAP

Exigido: 2 roll-up ou drill-down, 1 slice and dice, 1 pivot, 1 drill-across.
Feito: 3, 1, 1 e 3.

C1 drill-down

Fila de creche: município → DRE → distrito

528 crianças

em dez/2024; Ipiranga lidera (103)

Fila

C2 roll-up

Matrículas: etapa → nível → total, ano a ano

1,42 milhão

de matrículas em 2024; creche +48% desde 2015

Matrícula

C3 slice and dice

Creche por rede e jornada, 2019 e 2024

85% conveniada

e quase toda em jornada integral, nos dois anos

Matrícula

C4 pivot

DRE nas linhas, jornada nas colunas

35,5% a 47,2%

em jornada integral, por DRE (2024)

Matrícula

C5 drill-across

Fila contra matrícula ativa em junho, por distrito

-97%

na fila de creche em junho, de 2015 a 2024

Fila e Matrícula

C6 drill-across

Fila de creche e abandono no fundamental, por DRE

-0,27 a 0,56

correlação nas 13 DREs; o sinal muda entre os anos

Fila, Matrícula e Desfecho

C7 drill-across

0 a 4 anos: residentes, matriculadas e na fila

86 por 100

matrículas por 100 crianças residentes (31/07/2022)

População, Matrícula e Fila

C8 drill-down

Alunos por turma: município → DRE → distrito

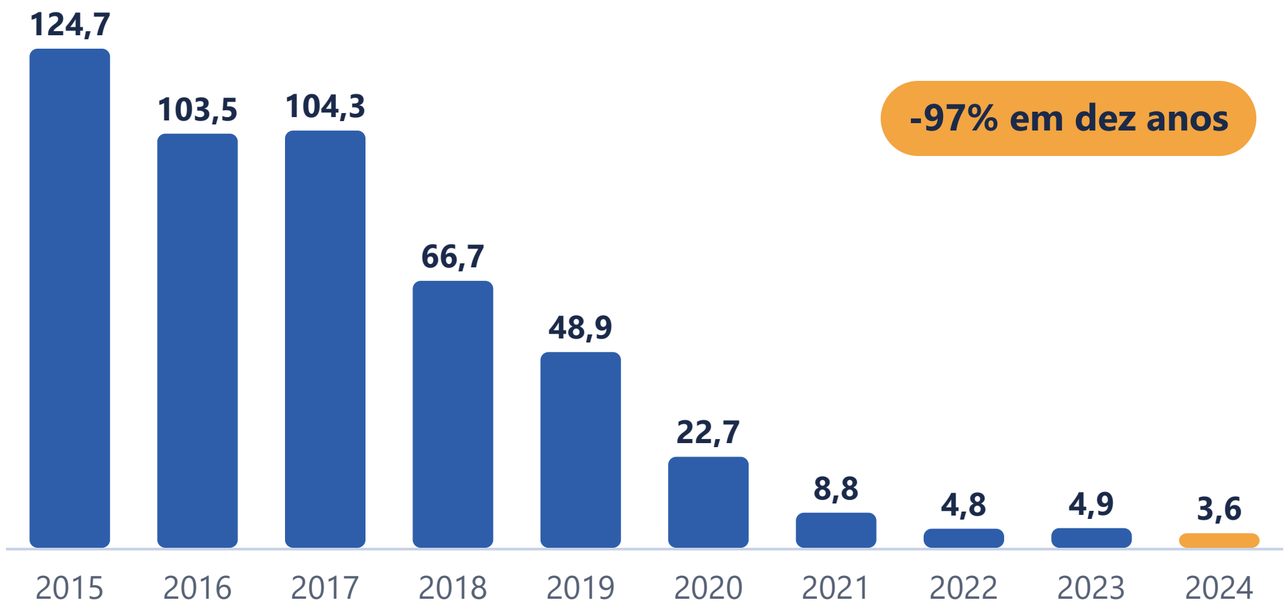
11 por turma

na creche; de 28,7 a 31,6 no fundamental

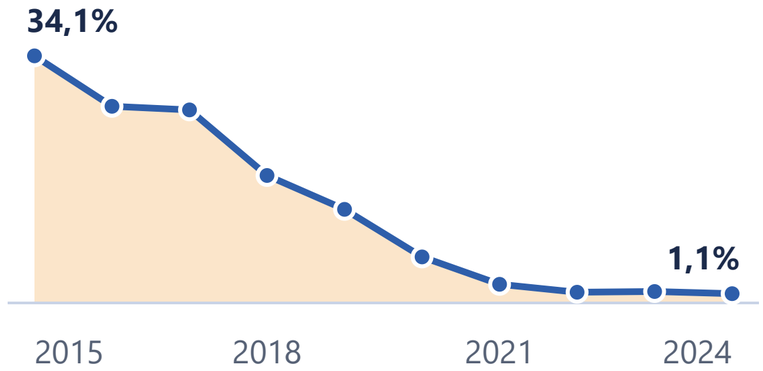
Ocupação de Turma

Resultados: fila e oferta de creche

Crianças na fila de creche em junho, em milhares (consulta 5)



Fração da demanda de creche fora da rede



85% da creche é conveniada, quase toda em jornada integral, em 2019 e em 2024 (consulta 3).

Fonte: SME-SP, Demanda Registrada e Matrículas e Microdados de Matrículas; consultas 3 e 5.

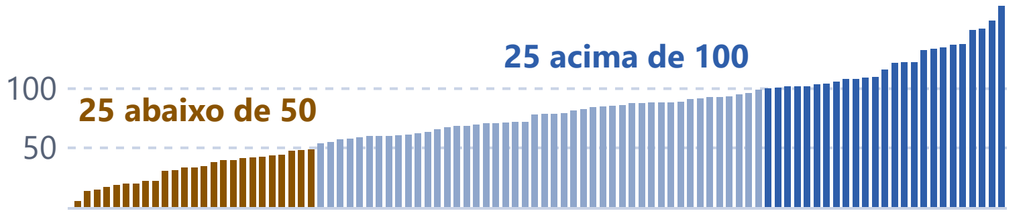
Resultados: população e ocupação das turmas

CONSULTA 7 · 31/07/2022

86 **matrículas por 100 crianças de 0 a 4 anos**

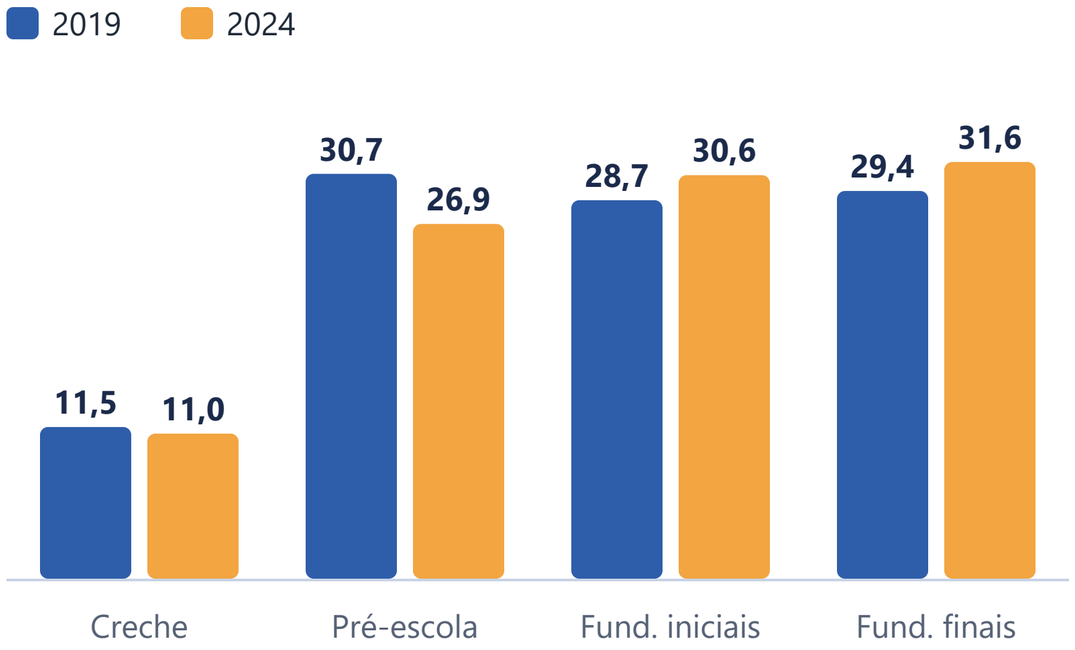
514.131 matrículas ativas para 598.406 crianças residentes.

Por distrito, longe da média (96 distritos)



Extremos: Jardim Paulista (4,7) e Lajeado (169,7). A matrícula conta onde a escola fica.

Alunos por turma em 30 de junho (consulta 8)



Fonte: Censo 2022 (IBGE) e Microdados de Matrículas (SME-SP); consultas 7 e 8.

Decisões de projeto em destaque

1 **Grão mais fino na matrícula**

vínculo aluno-turma: preserva perfil e desfecho de cada aluno

2 **Rollups encolhidos**

cada fato mantém o seu grão; Etapa, Tempo, Faixa Etária e Território conformam

3 **Nulo não é zero**

medida não publicada fica nula; zero faria a fila sumir

4 **Escola tipo 2**

402 escolas mudam de nome, tipo, distrito ou DRE na série

5 **Capacidade não inventada**

ocupação medida pelos alunos ativos; nenhuma vaga estimada

6 **Datas de referência**

junho para fila × matrícula; 31/07/2022 para população × matrícula

A decisão: a próxima vaga vai para o Tremembé

GRAJAÚ · O MAIOR DISTRITO

24.398 crianças de 0 a 4 anos (Censo 2022)

82,7 matrículas por 100 crianças (2022)

88 na fila de creche em junho de 2024; eram 8.018 em 2015

TREMEMBÉ · DISTRITO DA ANA

11.498 crianças de 0 a 4 anos (Censo 2022)

71,6 matrículas por 100 crianças, abaixo da média de 86

153 na fila de creche em junho de 2024, a segunda maior da cidade

O que o cruzamento mostra: pelo tamanho, a escolha seria o Grajaú; com fila, oferta e população lado a lado, a próxima vaga pesa mais no Tremembé.

Fonte: consultas 5 e 7; a matrícula conta onde fica a escola, e a população, onde mora a criança.

Fim da história: a Ana consegue a vaga

CENÁRIO HIPOTÉTICO

1. A prefeitura abre turmas de creche no Tremembé.
2. A Ana sai da fila e vira uma linha do fato Matrícula.
3. A mãe da Ana volta a trabalhar.

O QUE O DATA WAREHOUSE TROUXE

Uma consulta no lugar de três bases
fila, matrícula, ocupação e população lado a lado, por distrito

Números confiáveis
14 verificações a cada carga e as bases da SME reconciliadas entre si

Dez anos de histórico
onde a fila caiu e onde ela resiste

Atualização com um comando
quando a prefeitura publica dados novos

A mesma consulta serve para a próxima Ana, em qualquer um dos 96 distritos.

Cenário hipotético. Números reais das consultas 5, 7 e 8 sobre a carga com os dados reais.

Obrigado. Perguntas?

13,4 mi
matrículas de 2015 a 2024

551 mil
turmas carregadas

26.889
setores censitários

- Relatório: descrição do problema, povoamento atributo por atributo, cinco estrelas, constelação e oito consultas.
- Repositório: pipeline do portal ao DuckDB, 14 verificações de qualidade e testes automáticos, inclusive da modelagem.
- Carga real: 13,4 milhões de matrículas, 551 mil turmas e 26.889 setores censitários em 3,5 minutos, sem nenhuma FALHA nas verificações.

github.com/kevennlaranjeira/OLAP2026

Kevenn Laranjeira de Oliveira · Thiago Rodrigues Gouveia da Silva · Daniel Afonso Borges dos Santos · Luís Antônio Arruda Soares