Universidade de São Paulo
Instituto de Ciências Matemáticas e de Computação
Departamento de Ciências de Computação

[NOME DO CURSO]

SCC0245 Processamento Analítico de Dados
Profa. Dra. Cristina Dutra de Aguiar

Primeiro Trabalho Prático

Rede Municipal Paulistana: oferta escolar e demanda não atendida

Projeto temático: política pública municipal

Grupo 7

Integrante	**Nº USP**
Kevenn Laranjeira de Oliveira	18046529
Thiago Rodrigues Gouveia da Silva	18066911
Daniel Afonso Borges dos Santos	12608581
Luís Antônio Arruda Soares	12559486

São Carlos, [DATA DE ENTREGA]

Sumário

1 Descrição do problema **2**
1.1 Tema geral . . . 2
1.2 Assuntos de interesse e processos de negócio . . . 2
1.3 Fontes de dados . . . 3
1.4 Grão, dimensões e fatos de cada processo . . . 4
1.5 Dimensões e atributos . . . 5
1.6 Fatos . . . 10
1.7 Povoamento e integração . . . 12

2 Esquemas **15**
2.1 Esquema estrela Matrícula . . . 15
2.2 Esquema estrela Fila . . . 16
2.3 Esquema estrela Desfecho . . . 16
2.4 Esquema estrela Ocupação de Turma . . . 17
2.5 Esquema estrela População . . . 17
2.6 Constelação de fatos . . . 18

3 Consultas **21**
3.1 Consulta 1: drill-down . . . 21
3.2 Consulta 2: roll-up . . . 21
3.3 Consulta 3: slice and dice . . . 21
3.4 Consulta 4: pivot . . . 21
3.5 Consulta 5: drill-across . . . 21
3.6 Consulta 6: drill-across . . . 22
3.7 Consulta 7: drill-across . . . 22
3.8 Consulta 8: drill-down . . . 22

A Viabilidade: o modelo povoado com os dados reais **24**

1 Descrição do problema

1.1 Tema geral

O trabalho modela a oferta escolar e a demanda não atendida na rede municipal de educação de São Paulo entre 2015 e 2024. A pergunta que organiza o modelo é onde existe fila por vaga, onde existe oferta, se a oferta que existe está cheia, quantas crianças moram em cada lugar e o que acontece com o aluno que consegue a vaga.

Problema de política pública. A falta de vaga em creche foi por anos o principal problema de acesso da educação infantil paulistana. O Plano Nacional de Educação (Lei 13.005/2014) fixou, na Meta 1, a universalização da pré-escola para crianças de 4 e 5 anos e a ampliação da creche para atender pelo menos metade das crianças de até 3 anos. A prefeitura publica a fila de espera por distrito justamente para dar transparência a esse problema. Para decidir onde abrir vagas, o gestor municipal precisa cruzar quatro informações que ficam em lugares diferentes: quem pediu vaga e não foi atendido (fila), quem está matriculado (oferta usada), se as turmas que existem estão cheias (ocupação) e quantas crianças moram em cada região (demanda potencial). O data warehouse junta as quatro no mesmo modelo e acrescenta uma quinta, o desfecho da matrícula, para acompanhar o que acontece depois do acesso.

Decisões que o modelo apoia. A Secretaria Municipal de Educação e as Diretorias Regionais de Educação (DREs) podem usar o modelo para: (i) priorizar distritos para expansão de vagas de creche e pré-escola (consultas 1, 5 e 7); (ii) acompanhar o peso da rede conveniada e da jornada integral na oferta (consultas 3 e 4); (iii) decidir se a expansão exige turma nova ou pode usar lugar em turma existente (consulta 8); (iv) verificar se as regiões com falta de vaga são as mesmas com abandono escolar, para orientar programas de permanência (consulta 6).

Viabilidade e escolha do município. A Secretaria Municipal de Educação (SME) publica ao mesmo tempo o microdado de cada matrícula e a fila de espera por distrito, o que permite medir a demanda não atendida em vez de estimá-la, com dados reais e volumosos (13,4 milhões de matrículas em dez anos). O enunciado temático prioriza São Carlos, e a primeira proposta do grupo foi dimensionar a oferta escolar por setor censitário naquele município. A verificação das bases mostrou que, sem dado aberto de vaga nem de fila, a demanda não atendida teria de ser estimada; por isso o grupo trocou para São Paulo. O modelo, porém, não depende de São Paulo: os fatos de matrícula, de turma e de desfecho vêm do tipo de registro que o sistema de gestão escolar descrito no enunciado temático mantém para qualquer rede (cadastro de aluno, matrícula, turma e resultado), e a população por setor censitário do Censo 2022 existe para todos os municípios, inclusive São Carlos. Bastaria que o município registrasse e publicasse a fila para que o mesmo modelo fosse aplicado a ele.

1.2 Assuntos de interesse e processos de negócio

O grupo registrou cinco assuntos de interesse. Cada um é sustentado por um processo de negócio com sua tabela de fatos, ou por atributos do modelo, como mostra a Tabela 1.

Assunto de interesse	Onde está no modelo
Matrículas	processo Matrícula (tabela de fatos Matrícula)
Fila (demanda registrada)	processo Fila por vaga (tabela de fatos Fila)
Capacidade e ocupação das turmas	processo Ocupação de turma (tabela de fatos Ocupação de Turma); a capacidade de cada turma não é publicada por nenhuma fonte e não é estimada, mas a fila traz as matrículas em processo, que são vagas oferecidas aguardando documentação
População em idade escolar	processo População residente (tabela de fatos População)
Oferta escolar por setor	rede da escola (setor público direto ou conveniado) na dimensão Escola; território na dimensão Território (distrito, DRE) e na dimensão Setor Censitário; consultas 3, 4, 7 e 8

Tabela 1: Assuntos de interesse registrados pelo grupo.

O modelo tem cinco processos de negócio:

1. **Matrícula.** Registra a ocupação de vagas: cada vínculo de um aluno com uma turma em um ano letivo. É a oferta efetivamente utilizada.
2. **Fila por vaga.** Registra a demanda não atendida: quantas crianças estão inscritas esperando vaga, por distrito e etapa, em cada mês de referência publicado.
3. **Desfecho da matrícula.** Registra o que aconteceu com quem conseguiu a vaga: aprovação, reprovação, abandono, transferência ou conclusão, agregados por escola, ano e série.
4. **Ocupação de turma.** Registra, para cada turma de cada ano, quantos alunos ela teve e quantos estavam ativos no meio do ano letivo. É a medida de quanto da oferta existente está ocupada.
5. **População residente.** Registra quantas pessoas de cada faixa etária moram em cada setor censitário na data de referência do Censo 2022. É a demanda potencial, que existe mesmo quando ninguém pediu vaga.

1.3 Fontes de dados

São três fontes reais e oficiais. As duas primeiras vêm do Portal de Dados Abertos da Prefeitura de São Paulo, publicadas pela SME sob licença Creative Commons; a terceira é do IBGE. Elas têm grão, formato e vocabulário diferentes.

	Microdados da Rede Municipal de Educação, Matrículas (SME)	**Demanda Registrada e Matrículas (SME)**	**Censo Demográfico 2022, Agregados por Setores Censitários (IBGE)**
Grão publicado	uma matrícula (vínculo de um aluno com uma turma)	um distrito, com uma coluna por etapa de ensino	um setor censitário, com uma coluna por grupo de idade
Periodicidade	anual	trimestral até 2022, bimestral a partir de 2023; série histórica de 2006 a 2017	decenal; data de referência na noite de 31/07 para 01/08/2022
Volume no recorte	13,4 milhões de matrículas de escolarização	44 planilhas, 96 distritos cada	setores do município de São Paulo, dentro do arquivo nacional
Conteúdo usado	escola, turma, turno, série, idade, sexo, raça e cor, deficiência, datas e desfecho da matrícula	matrículas, matrículas em processo e demanda registrada (fila) por etapa	pessoas residentes por grupo de idade (tema Demografia, variáveis V01031 a V01041) e nome do distrito (tema Básico)

Tabela 2: Fontes de dados.

1.4 Grão, dimensões e fatos de cada processo

Processo	**Grão**	**Dimensões**	**Fatos**
Matrícula	vínculo aluno-turma em um ano letivo	Ano Letivo, Data (início e fim), Escola, Território, Série, Turno, Idade, Perfil do Aluno, Deficiência, Situação da Matrícula	quantidade de matrículas (campo artificial), dias de matrícula
Fila por vaga	distrito, mês de referência e etapa	Tempo, Território, Etapa	matrículas, matrículas em processo, demanda total e suas categorias
Desfecho	escola, ano letivo e série	Ano Letivo, Escola, Território, Série	matrículas e contagem por desfecho; taxas derivadas
Ocupação de turma	turma em um ano letivo	Ano Letivo, Escola, Território, Série, Turno	quantidade de turmas (campo artificial), matrículas no ano, matrículas e turmas ativas em junho; alunos por turma (derivado)
População residente	setor censitário, faixa etária e data de referência do Censo	Tempo, Setor Censitário, Território, Faixa Etária	quantidade de pessoas

Tabela 3: Grão, dimensões e fatos.

No processo de matrícula, o grão é o mais fino que a fonte permite. Isso preserva o perfil de cada aluno, que se perderia em qualquer agregação. No processo de fila, o grão é aquele em que a prefeitura publica, pois não há dado abaixo do distrito. O processo de desfecho é um fato agregado: taxas de rendimento só fazem sentido sobre um conjunto de alunos, e o grão escolhido é o de escola, ano e série. O processo de ocupação também é agregado, porque a ocupação é uma propriedade da turma e não do aluno. O processo de população usa o grão em que o IBGE publica, o setor

censitário, que é a menor unidade territorial do modelo e mostra onde, dentro de cada distrito, as crianças moram.

1.5 Dimensões e atributos

Todas as dimensões têm chave primária artificial (inteiro sequencial gerado na carga). As chaves naturais da origem são guardadas como atributos. Nas tabelas, a coluna "Papel" indica se o atributo é chave, se participa de uma hierarquia ou se é apenas descritivo, e a coluna "Povoamento" indica de qual fonte e de qual coluna o valor vem e se há integração. Os nomes de coluna da origem estão em `fonte monoespaçada`. As hierarquias de cada dimensão estão na Seção 2.

1.5.1 Dimensão Tempo

Representa o mês de referência. É usada pelo fato Fila, que a prefeitura publica por mês, e pelo fato População, no mês do Censo. Grão: mês. Os atributos de calendário se relacionam em duas hierarquias (mês, trimestre, semestre e ano; mês, bimestre e ano); os demais são descritivos.

Atributo	Significado	Papel	Povoamento
chave tempo	chave artificial	chave	gerada na carga
data referência, ano mês	primeiro dia do mês e rótulo AAAA-MM	descritivo	calendário gerado para o recorte (2015 a 2024)
mês, nome mês	mês do ano	hierarquia	derivado da data
bimestre, trimestre, semestre	agrupamentos do mês	hierarquia	derivado da data
ano	ano civil	hierarquia	derivado da data
fila publicada	há planilha de fila para o mês	descritivo	Demanda Registrada: mês e ano lidos do nome do arquivo ou de `MES_ANO_REF` na série histórica
observação	nota técnica do mês	descritivo	Demanda Registrada: notas de rodapé da planilha (por exemplo, a greve de março de 2018); no mês do Censo, a data de referência do IBGE

1.5.2 Dimensão Data (visão para dois papéis)

Representa um dia do calendário. É usada duas vezes pelo fato Matrícula: data de início e data de fim da matrícula, da mesma forma que a Dimensão Data do artigo da disciplina representa a data de internação e a data de alta. As duas datas permitem contar as matrículas ativas em um dia, que é a medida comparável com a fila e com a população. Grão: dia. O membro com data nula representa "não informada".

Atributo	Significado	Papel	Povoamento
chave data	chave artificial	chave	gerada na carga
data	o dia	hierarquia	calendário gerado de um ano antes a um ano depois do recorte; o fato aponta para ele a partir de `DT_IN_MAT` e `DT_FIM_MAT` do microdado, lidas em cinco formatos

Atributo	Significado	Papel	Povoamento
dia, mês, nome mês, trimestre, semestre, ano	componentes do calendário	hierarquia	derivados da data
dia da semana, nome do dia, fim de semana	posição na semana	descritivo	derivados da data

1.5.3 Dimensão Ano Letivo

Representa o ano letivo do microdado. É o rollup encolhido das dimensões Tempo e Data, conformada com elas pelo atributo ano.

Atributo	Significado	Papel	Povoamento
chave ano letivo	chave artificial	chave	gerada na carga
ano	ano letivo	hierarquia (topo)	Microdados: `AN_LETIVO` e ano do arquivo
qualidade código escola	confiável, consistente só no ano ou corrompido	descritivo	medida no próprio microdado: proporção de códigos em notação científica e de códigos compartilhados por escolas diferentes
observação	limitações do microdado do ano	descritivo	escrita pela carga a partir de métricas do dado (turno não publicado, datas ausentes, retrato antes do fim do ano)

1.5.4 Dimensão Território

Representa um distrito do município. É compartilhada pelos cinco fatos. Grão: distrito. Distrito, DRE, município e UF formam uma hierarquia; a participação da DRE é descritiva.

Atributo	Significado	Papel	Povoamento
chave território	chave artificial	chave	gerada na carga
distrito	um dos 96 distritos, ou "não informado"	hierarquia	integração das três fontes: `NOME_DISTRITO` do microdado, coluna de distrito da planilha de fila e `NM_DIST` do IBGE, todos levados a maiúsculas sem acento e sem espaço sobrando
DRE	Diretoria Regional de Educação predominante do distrito	hierarquia	Microdados: `DRE` normalizada; para cada distrito, a DRE com mais matrículas
participação DRE	fração das matrículas do distrito que pertencem a essa DRE	descritivo	calculada no microdado
município, UF	São Paulo, SP	hierarquia	constante

1.5.5 Dimensão Escola (mudança lenta tipo 2)

Representa uma versão de uma unidade escolar. Uma nova versão começa quando nome, tipo, distrito ou DRE mudam; setor e situação guardam o último valor dentro da versão. Escola, tipo e rede formam uma hierarquia; os demais atributos são descritivos.

Atributo	Significado	Papel	Povoamento
chave escola	chave artificial da versão	chave	gerada na carga
código escola	código da unidade na SME	chave natural	Microdados: `CD_UNIDADE_EDUCACAO`; de 2022 a 2024, recuperado pelo nome, tipo e distrito contra o último ano com código confiável; sem correspondência, código sintético estável
código sintético	a escola nunca teve código confiável publicado	descritivo	calculado na identificação
versão, ano início, ano fim, versão atual	vigência da versão	controle	calculados na carga (mudança lenta tipo 2)
nome escola	nome da unidade	descritivo	Microdados: `NOME_ESCOLA`
tipo escola	EMEI, EMEF, CEI, creche conveniada, CEU e outros	hierarquia	Microdados: `TIPO_ESCOLA`, com as grafias de cada ano unificadas
rede	direta, conveniada, outras secretarias ou particular	hierarquia	derivada do tipo da escola
distrito, DRE	localização administrativa	descritivo	Microdados: `NOME_DISTRITO` e `DRE` normalizados
setor SME	setor administrativo da Secretaria	descritivo	Microdados: `CD_SETOR`; não é o setor censitário do IBGE (homônimo)
situação	ativa, extinta, paralisada ou criada	descritivo	Microdados: `SITUACAO_ESCOLA`

1.5.6 Dimensão Série

Representa a série publicada no microdado, identificada pela combinação de modalidade, segmento e série. Série, etapa e nível formam uma hierarquia; série e ciclo formam outra, paralela, porque o ciclo interdisciplinar cobre o 4º, 5º e 6º anos e atravessa a fronteira entre anos iniciais e finais.

Atributo	Significado	Papel	Povoamento
chave série	chave artificial	chave	gerada na carga
modalidade, segmento, série	combinação publicada (chave natural)	hierarquia (série)	Microdados: `MODALIDADE`, `MODALIDADE_SEGMENTO`, `DESC_SERIE`
ciclo	alfabetização, interdisciplinar ou autoral	hierarquia	derivado do texto da série
ordem da série	ano do fundamental	descritivo	derivado do texto da série
educação especial	turma de educação especial	descritivo	derivado do segmento ou do texto da série
código etapa, etapa, nível	etapa conformada com a dimensão Etapa	hierarquia	classificação das 148 combinações reais por regra testada

1.5.7 Dimensão Etapa

Representa uma etapa de ensino. É o rollup encolhido da dimensão Série, usado pelo fato Fila, que a prefeitura publica por etapa. As etapas são creche, pré-escola, ensino fundamental anos iniciais e anos finais, ensino médio, EJA anos iniciais e anos finais, MOVA, ProJovem e educação profissional.

Atributo	Significado	Papel	Povoamento
chave etapa	chave artificial	chave	gerada na carga
código	CRECHE, PRE, FUND_I, ...	chave natural	catálogo do projeto, conformado com os rótulos das colunas da planilha de fila (“Creche”, “Pré Escola”, “Ens. Fund.I”) e com a modalidade do microdado
etapa, nível	nome e nível de ensino	hierarquia	catálogo do projeto
ordem	ordem de exibição	descritivo	catálogo do projeto

1.5.8 Dimensão Turno

Representa o turno da turma. Turno e jornada formam uma hierarquia.

Atributo	Significado	Papel	Povoamento
chave turno	chave artificial	chave	gerada na carga
turno	manhã, intermediário, tarde, vespertino, noite, integral ou não informado	hierarquia	Microdados: `DESC_TURNO`; em 2021, deduzido de `CD_TURNO`; em parte de 2022, de `HORA_IN_TURMA` e `HORA_FIM_TURMA`
jornada	parcial diurno, noturno ou integral	hierarquia	derivada do turno
origem turno	publicado, código de 2021, horário ou não informado	descritivo	registrada pela regra que resolveu o turno

1.5.9 Dimensão Idade

Representa a idade do aluno em 31 de março do ano letivo. Tem duas hierarquias paralelas: idade, faixa escolar e grupo etário; e idade e faixa do IBGE, que conforma esta dimensão com a dimensão Faixa Etária.

Atributo	Significado	Papel	Povoamento
chave idade	chave artificial	chave	gerada na carga
idade	idade em 31/03; nula no membro “não informada”	hierarquia	Microdados: `IDADE_ALUNO_31_03`, `IDADE_ALUNO_3103` ou `IDADE_ALUNO_MAR`, conforme o ano; se ausente ou impossível, calculada por `ANO_NASC_ALUNO` e `MES_NASC_ALUNO`
faixa escolar	0 a 3, 4 e 5, 6 a 10, 11 a 14, 15 a 17, 18 a 29, 30 ou mais	hierarquia	derivada da idade
grupo etário	criança, adolescente, adulto, idoso	hierarquia	derivado da idade
faixa IBGE	0 a 4, 5 a 9, ..., 70 ou mais	hierarquia	derivada da idade, com o mesmo corte do tema Demografia do Censo 2022

1.5.10 Dimensão Faixa Etária

Representa um grupo de idade do Censo 2022. É o rollup encolhido da dimensão Idade, conformada com ela pelo atributo faixa IBGE, e é usada pelo fato População. É carregada como catálogo mesmo que a população não esteja carregada.

Atributo	Significado	Papel	Povoamento
chave faixa etária	chave artificial	chave	gerada na carga
faixa IBGE	0 A 4 ANOS, 5 A 9 ANOS, ..., 70 ANOS OU MAIS	hierarquia (topo)	catálogo do projeto, com o mesmo rótulo da dimensão Idade
idade inicial, idade final	limites da faixa; final nula na faixa aberta	descritivo	catálogo do projeto
variável IBGE	variável de origem	descritivo	dicionário do IBGE: `V01031` a `V01041`
ordem	ordem de exibição	descritivo	catálogo do projeto

1.5.11 Dimensão Setor Censitário

Representa um setor censitário do município no Censo 2022. Setor, distrito, DRE, município e UF formam uma hierarquia; a DRE é obtida pela conformidade com a dimensão Território no distrito. É a dimensão de grão mais fino do território, e só a população é publicada nela.

Atributo	Significado	Papel	Povoamento
chave setor censitário	chave artificial	chave	gerada na carga
código setor	15 dígitos: UF, município, distrito, subdistrito e setor	chave natural	IBGE: `CD_SETOR`; entram só os setores que começam pelo código do município (3550308)
código distrito IBGE	9 primeiros dígitos do setor	descritivo	derivado do código do setor
nome distrito IBGE	grafia publicada pelo IBGE, com acento	descritivo	IBGE, tema Básico: `NM_DIST`; se o setor não estiver no tema Básico, o nome mais comum entre os setores do mesmo distrito
distrito	nome normalizado	hierarquia	integração: mesma normalização do distrito da SME; liga o setor à dimensão Território
município, UF	São Paulo, SP	hierarquia	constante

1.5.12 Dimensões bugiganga

Três dimensões agrupam indicadores de baixa cardinalidade que, sozinhos, gerariam dezenas de dimensões de duas ou três linhas. Todos os seus atributos são descritivos. Em todas elas, um indicador inexistente no arquivo de um ano fica nulo (não coletado), não falso: quatro indicadores de deficiência só passam a existir em 2024, e marcá-los como falso antes disso faria parecer que nenhum aluno tinha a condição.

Atributo	Significado	Papel	Povoamento
Dimensão Perfil do Aluno			
chave perfil aluno, código combinação	chave artificial e combinação dos quatro valores	chave, chave natural	gerados na carga
sexo	sexo do aluno	descritivo	Microdados: `CD_SEXO`
raça e cor	raça e cor declarada	descritivo	Microdados: `DESC_RACA_COR`, com grafias unificadas (“NAO DECLARADA”, “NÃO DECLARADA”)

Atributo	Significado	Papel	Povoamento
altas habilidades	indicador de altas habilidades	descritivo	Microdados: `NEE_ALT_HAB`
idade estimada	a idade foi estimada só pelo ano de nascimento	descritivo	registrado pela regra da idade
Dimensão Deficiência			
chave deficiência, código combinação	chave artificial e texto de 17 posições (1, 0 ou - não coletado)	chave, chave natural	gerados na carga
17 indicadores	autismo, deficiência intelectual, baixa visão, síndrome de Down e outros	descritivo	Microdados: `DEF_*` (2015-2017) ou `DEF__*` (2018 em diante)
possui deficiência, quantidade	resumo dos indicadores	descritivo	derivados dos 17 indicadores
Dimensão Situação da Matrícula			
chave situação, código combinação	chave artificial e texto de 12 posições mais a situação	chave, chave natural	gerados na carga
12 indicadores	aprovado, reprovado, abandono, concluído, transferido, falecido e outros	descritivo	Microdados: `SIT_AL_*`
situação matrícula	situação textual	descritivo	Microdados: `SITUACAO_MAT`
desfecho	resumo exclusivo da situação final	descritivo	derivado com prioridade explícita: falecido, transferido, abandono, reprovado, aprovado, concluído, outra saída, em curso

1.6 Fatos

Fato	Aditividade	Significado, derivação e povoamento
Tabela de fatos Matrícula		
quantidade de matrículas	aditivo	campo artificial sempre igual a 1, como a contagem de utilização do esquema de ocupação do artigo da disciplina; a tabela é praticamente sem fato
dias de matrícula	aditivo	duração do vínculo; Microdados: `QTD_DIAS_MAT` ou `QTD_DIAS_MATR`; nulo em 2021, que não publicou datas
id turma, código matrícula	dimensões degeneradas	id turma construído com ano, escola, `NOME_TURMA`, série e turno, porque `CD_TURMA` está corrompido de 2022 em diante; código matrícula de `CD_MAT`, nulo nos anos de código corrompido
Tabela de fatos Fila		

Fato	**Aditividade**	**Significado, derivação e povoamento**
matrículas, matrículas em processo	semiaditivo	estoques na data de referência: somam entre distritos e etapas, não ao longo do tempo; Demanda Registrada: grupos de colunas de matrícula e de matrícula em processo de cada etapa
demanda total	semiaditivo	idem; somar meses contaria a mesma criança várias vezes; Demanda Registrada: total da demanda de cada etapa
demanda sem opção, sem opção até 30 dias, sem opção mais de 30 dias, com opção por unidade	semiaditivo	colunas numeradas (1), (2) e (3), com significado lido das notas de rodapé de cada arquivo; nulas nos períodos em que a prefeitura não publicou a quebra
Tabela de fatos Desfecho		
matrículas e contagens por desfecho	aditivo	agregadas do fato Matrícula pelo desfecho da dimensão Situação; as contagens são exclusivas e somam o total de matrículas
taxas de aprovação, reprovação e abandono	não aditivo, derivado	divisão da contagem pela soma de aprovados, reprovados e abandonos, como no indicador de rendimento do INEP; recalculada em cada nível, nunca como média de taxas; nula na educação infantil
Tabela de fatos Ocupação de Turma		
quantidade de turmas	aditivo	campo artificial igual a 1
matrículas no ano	aditivo	vínculos da turma no ano, agregados do fato Matrícula; a soma é igual à do fato Matrícula
matrículas ativas em junho, turmas ativas em junho	aditivo	alunos com início até 30/06 e fim depois dessa data ou não informado; turma ativa é a que tinha ao menos um aluno ativo; nulas nos anos sem datas publicadas (2021), nunca zero
alunos por turma	não aditivo, derivado	soma das matrículas ativas dividida pela soma das turmas ativas, recalculada em cada nível de agregação
Tabela de fatos População		
quantidade de pessoas	semiaditivo	estoque na data do Censo: soma entre setores, distritos e faixas, não entre Censos; IBGE, tema Demografia, `V01031` a `V01041`; valor não numérico na origem fica nulo (não publicado), nunca zero

1.7 Povoamento e integração

1.7.1 Origem de cada parte do modelo

Parte do modelo	Origem
Fato Matrícula; dimensões Escola, Série, Turno, Idade, Data, Perfil, Deficiência e Situação	Microdados de Matrículas
Fato Fila; dimensão Tempo	Demanda Registrada e Matrículas
Fatos Desfecho e Ocupação de Turma	agregados a partir do fato Matrícula
Fato População; dimensão Setor Censitário	Censo 2022, Agregados por Setores (temas Demografia e Básico)
Dimensão Território	distritos das três fontes; DRE predominante calculada a partir do microdado
Dimensões Etapa e Faixa Etária	catálogos do projeto, conformados com o vocabulário das fontes
Dimensão Ano Letivo	anos do microdado; qualidade e observações medidas no próprio dado

1.7.2 Integração entre as duas fontes da SME

Distrito. As duas fontes identificam o distrito pelo nome, em maiúsculas e sem acento, com variação de espaços. Normalizados, os 96 nomes de uma fonte coincidem um a um com os da outra.

DRE. A planilha de fila não traz a DRE. Ela é obtida do microdado: para cada distrito, a DRE com mais matrículas. Entre 2015 e 2021, no máximo dois distritos por ano têm escolas em mais de uma DRE, e o atributo participação DRE registra a fração coberta pela regra. É essa integração que permite subir a fila de distrito para DRE.

Etapa. A planilha usa rótulos como “Creche”, “Pré Escola” e “Ens. Fund.I”; o microdado usa modalidade, segmento e série (por exemplo, `FUND` com segmento `Fund1` e série “C.II 5.ANO F9”). As duas são levadas ao mesmo catálogo de etapas.

Reconciliação. A planilha de fila também publica a matrícula por distrito e etapa. Contando no microdado as matrículas ativas no fim de junho pelo distrito da escola, as duas fontes concordam com diferença abaixo de 1% de 2015 a 2020, o que confirma a integração (detalhes no Apêndice A).

1.7.3 Integração com o Censo 2022

O mesmo dado aparece com representações diferentes nas fontes da SME e no IBGE, e o data warehouse define uma única representação para cada um.

Dado	SME	IBGE	Representação no data warehouse
Distrito	nome em maiúsculas, sem acento (“AGUA RASA”)	código de 9 dígitos no início do setor e nome com acento e caixa mista (“Água Rasa”)	nome normalizado pela mesma regra, chave natural da dimensão Território; código e grafia do IBGE guardados na dimensão Setor Censitário
Idade	idade simples em 31 de março do ano letivo	grupo de idade (0 a 4, 5 a 9, ...) na data do Censo	faixa IBGE como atributo da dimensão Idade, conformado com a dimensão Faixa Etária
Data	ano letivo e datas de matrícula	noite de 31/07 para 01/08/2022	mês de julho de 2022 na dimensão Tempo; a consulta 7 conta as matrículas ativas em 31/07/2022
Setor	`CD_SETOR` da SME: setor administrativo de 4 dígitos	`CD_SETOR` do IBGE: setor censitário de 15 dígitos	atributos com nomes distintos (setor SME na dimensão Escola, código setor na dimensão Setor Censitário), nunca cruzados

Tabela 4: Integração entre a SME e o IBGE.

Setor cujo distrito não exista na SME aponta para o membro “não informado” da dimensão Território, e a carga registra quantos são. Como a creche atende de 0 a 3 anos e a pré-escola de 4 e 5, mas o IBGE agrupa 0 a 4, a comparação entre matrícula e população é feita na faixa 0 a 4, agregando a matrícula pela faixa IBGE da idade do aluno, e não pela etapa. A população é contada onde a criança mora e a matrícula onde a escola fica, porque o microdado não traz endereço do aluno; a razão entre as duas é oferta por criança residente, não taxa de atendimento dos moradores.

1.7.4 Sinônimos e homônimos

São os dois problemas clássicos de integração citados no artigo da disciplina. Sinônimos: “PIRITUBA” e “PIRITUBA/JARAGUA” (mesma DRE); `IDADE_ALUNO_31_03`, `IDADE_ALUNO_3103` e `IDADE_ALUNO_MAR` (mesma coluna em anos diferentes); “AGUA RASA” na SME e “Água Rasa” no IBGE (mesmo distrito). Homônimos: o campo `CD_SETOR` da SME é um setor administrativo de quatro dígitos e não tem relação com o `CD_SETOR` do IBGE, de quinze; e escolas diferentes com mesmo nome, tipo e distrito (de 14 a 34 casos por ano), que nunca recebem o mesmo código recuperado.

1.7.5 Problemas das fontes e decisões

Problema encontrado	Decisão de integração
Sete formatos da planilha de fila entre 2006 e 2026	o significado de cada coluna é lido do cabeçalho de duas linhas, e o de (1), (2) e (3) das notas de rodapé de cada arquivo

Problema encontrado	**Decisão de integração**
Quebra da fila por tempo de espera publicada só a partir de 2020	medida nula onde não foi publicada, nunca zero
Código da escola corrompido de 2022 a 2024 (notação científica, centenas de escolas no mesmo código)	a qualidade do código é medida por ano no próprio dado; o código real é recuperado casando nome, tipo e distrito com o último ano confiável (94,8% a 98,6% das matrículas); o restante recebe código sintético
Escola que muda de nome mantendo o código	dimensão Escola de mudança lenta tipo 2
Turno não publicado em 2021	deduzido do código da turma, que em 2021 é o de 2020 somado de 3, conferido pelos horários
Idade com vírgula decimal, nula ou com ano de nascimento 1900	idade recalculada pelo nascimento; valores impossíveis tratados como não informados
Datas em cinco formatos, inclusive número serial do Excel	leitura de todos os formatos; datas fora da janela do ano letivo descartadas
Indicadores de desfecho conflitantes (aprovado e reprovado ao mesmo tempo)	desfecho resumido com prioridade explícita
Atividades complementares no mesmo arquivo de escolarização	excluídas, pois a fila só conta vagas de escolarização
Capacidade das turmas não publicada	ocupação medida pelos alunos ativos; nenhuma capacidade é estimada
Grupos de idade do IBGE que não recortam nas etapas	comparação na faixa 0 a 4 anos, pela faixa IBGE da dimensão Idade
Layout do arquivo do IBGE diferente do esperado	a leitura procura as colunas pelo nome e para com erro se faltar alguma ou se a maior parte dos valores não for número

2 Esquemas

A notação segue a do artigo da disciplina: cada dimensão é uma caixa com o nome da dimensão, a chave primária (PK) e os atributos; a tabela de fatos fica no centro, com borda mais grossa, as chaves estrangeiras (FK) e os fatos. Dimensões degeneradas, campos artificiais e fatos derivados estão indicados entre parênteses. Por espaço, algumas caixas mostram os atributos principais; a lista completa está na Seção 1.5. Nas hierarquias, $A \leq B$ indica a ordem parcial em que cada valor de A pertence a um único valor de B, ou seja, A é agregado em B.

2.1 Esquema estrela Matrícula

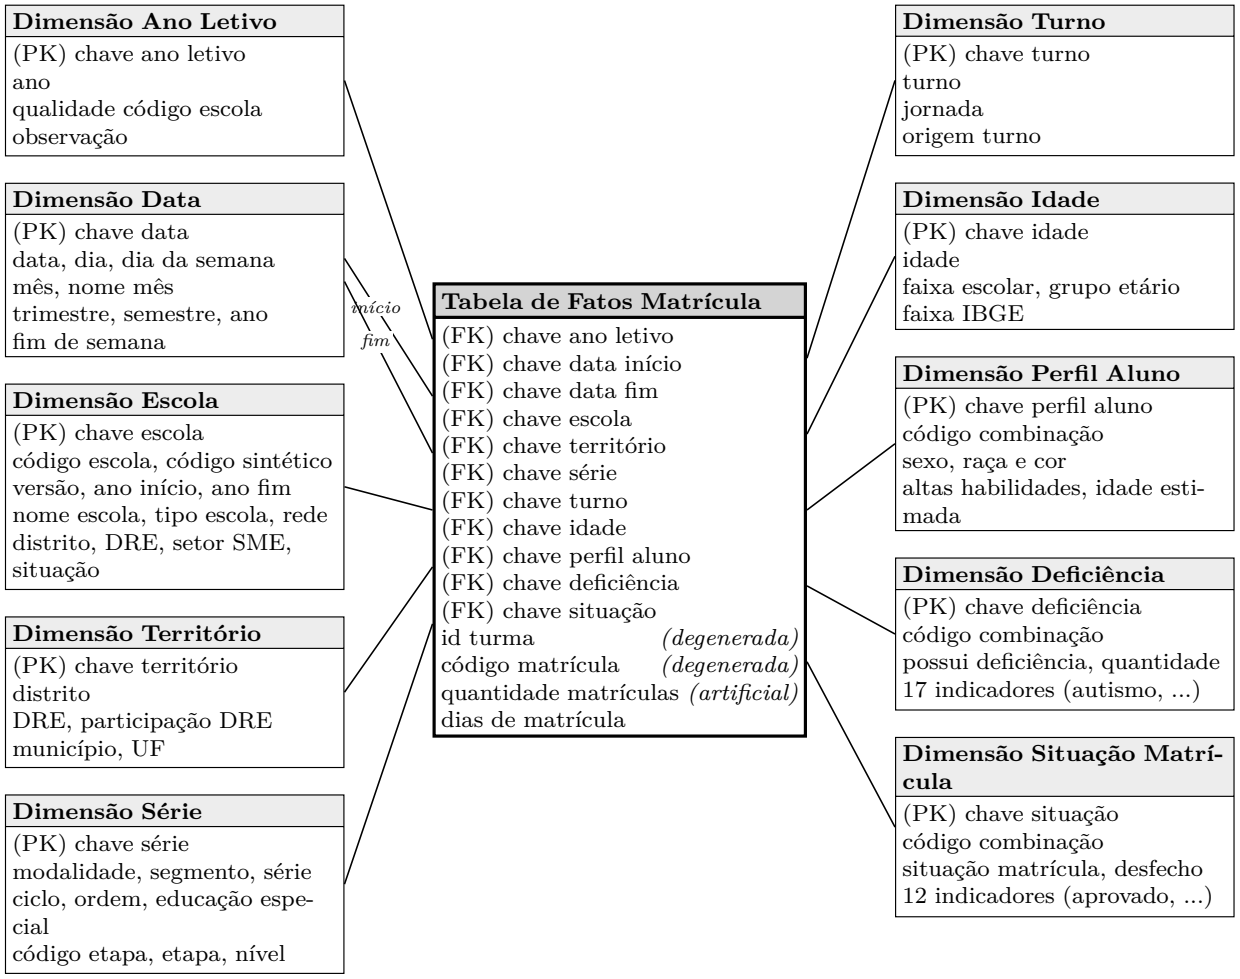


Figura 1: Esquema estrela do processo Matrícula. A Dimensão Data aparece com dois papéis (início e fim da matrícula).

Hierarquias.

- Data: dia $\leq$ mês $\leq$ trimestre $\leq$ semestre $\leq$ ano
- Território: distrito $\leq$ DRE $\leq$ município $\leq$ UF
- Escola: escola $\leq$ tipo de unidade $\leq$ rede
- Série: série $\leq$ etapa $\leq$ nível e, em paralelo, série $\leq$ ciclo
- Turno: turno $\leq$ jornada
- Idade: idade $\leq$ faixa escolar $\leq$ grupo etário e, em paralelo, idade $\leq$ faixa IBGE
- Ano Letivo, Perfil do Aluno, Deficiência e Situação: sem hierarquia; atributos descritivos.

Funções de agregação. Quantidade de matrículas: SOMA. Dias de matrícula: SOMA; a média é obtida dividindo pela quantidade de matrículas.

2.2 Esquema estrela Fila

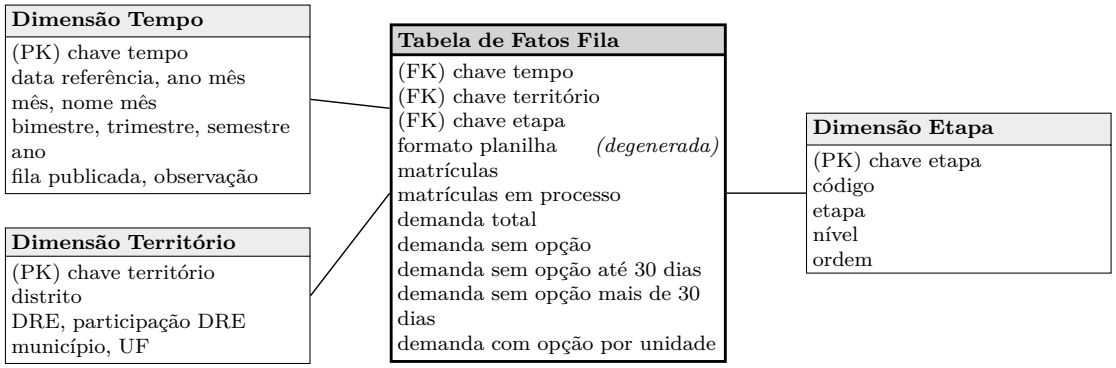


Figura 2: Esquema estrela do processo Fila por vaga.

Hierarquias.

- Tempo: mês $\leq$ trimestre $\leq$ semestre $\leq$ ano e mês $\leq$ bimestre $\leq$ ano. São duas porque a fila foi publicada por trimestre até 2022 e por bimestre depois.
- Território: distrito $\leq$ DRE $\leq$ município $\leq$ UF
- Etapa: etapa $\leq$ nível

Funções de agregação. Todos os fatos são estoques: SOMA nas dimensões Território e Etapa; na dimensão Tempo, o valor de um único mês (o último do período, ou MÉDIA entre meses). Somar meses contaria a mesma criança mais de uma vez.

2.3 Esquema estrela Desfecho



Figura 3: Esquema estrela do processo Desfecho da matrícula.

Hierarquias. As mesmas das dimensões Território, Escola e Série do esquema Matrícula; Ano Letivo sem hierarquia.

Funções de agregação. Matrículas e contagens por desfecho: SOMA. Taxas: não aditivas; em qualquer nível de agregação são recalculadas como contagem dividida pela soma de aprovados, reprovados e abandonos agregados naquele nível. Na educação infantil, que não tem aprovação nem reprovação, as taxas são nulas.

2.4 Esquema estrela Ocupação de Turma

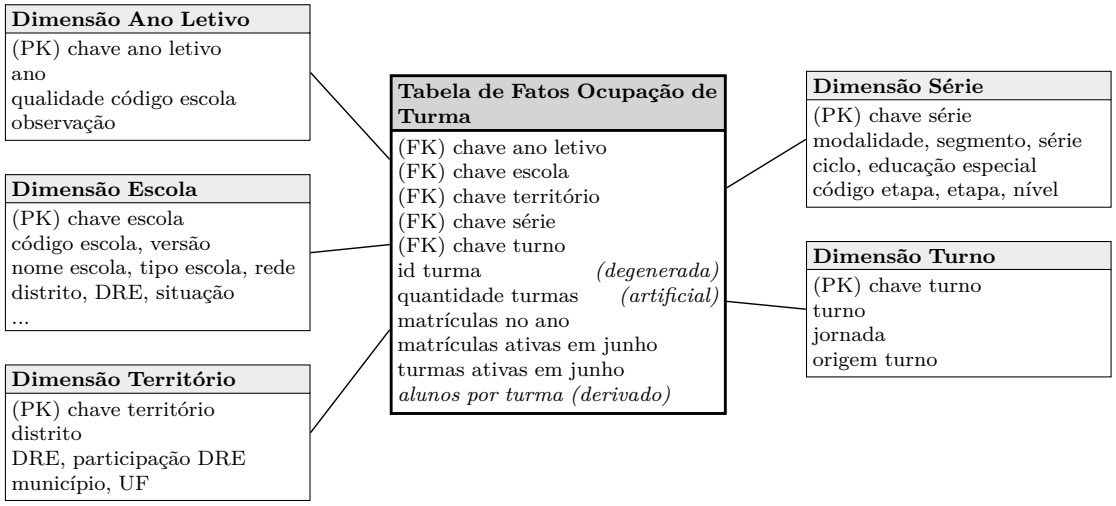


Figura 4: Esquema estrela do processo Ocupação de turma.

Hierarquias. As mesmas das dimensões Território, Escola, Série e Turno do esquema Matrícula; Ano Letivo sem hierarquia.

Funções de agregação. Quantidade de turmas, matrículas no ano, matrículas ativas em junho e turmas ativas em junho: SOMA. Alunos por turma: não aditivo; em qualquer nível é recalculado como SOMA das matrículas ativas dividida pela SOMA das turmas ativas, nunca como média das médias das turmas.

2.5 Esquema estrela População

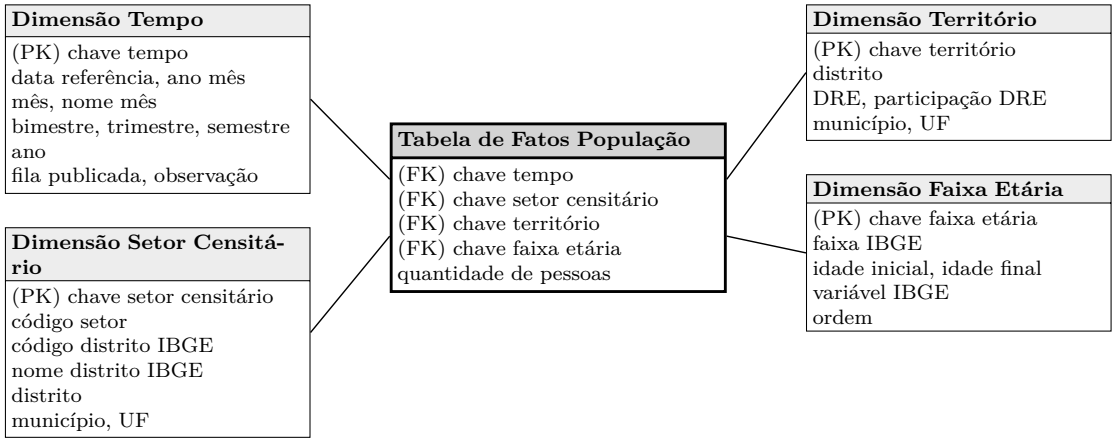


Figura 5: Esquema estrela do processo População residente.

Hierarquias.

- Setor Censitário: setor censitário $\leq$ distrito $\leq$ DRE $\leq$ município $\leq$ UF (a DRE vem da dimensão Território, pela conformidade no distrito)
- Território: distrito $\leq$ DRE $\leq$ município $\leq$ UF
- Tempo: as mesmas do esquema Fila
- Faixa Etária: sem hierarquia própria; é o topo da hierarquia idade $\leq$ faixa IBGE da dimensão Idade

Funções de agregação. Quantidade de pessoas é estoque: SOMA nas dimensões Setor Censitário, Território e Faixa Etária; na dimensão Tempo, o valor de um único Censo.

2.6 Constelação de fatos

As cinco estrelas formam uma constelação, desenhada na Figura 6 (página seguinte, em paisagem). A matriz de barramento abaixo resume quais dimensões conformadas cada tabela de fatos usa.

Dimensão	Matrícula	Fila	Desfecho	Turma	População
Território	×	×	×	×	×
Ano Letivo (ano)	×		×	×	
Tempo (mês)		×			×
Data (dia, dois papéis)	×				
Escola	×		×	×	
Série	×		×	×	
Etapa (rollup de Série)		×			
Turno	×			×	
Idade	×				
Faixa Etária (rollup de Idade)					×
Setor Censitário					×
Perfil do Aluno, Deficiência, Situação	×				

Tabela 5: Matriz de barramento: dimensões conformadas usadas por cada tabela de fatos.

Processo de projeto da constelação.

1. Cada processo foi modelado como uma estrela, começando pela declaração do grão.
2. As dimensões das cinco estrelas foram comparadas na matriz de barramento acima. Território, Escola, Série, Turno e Ano Letivo aparecem em mais de uma estrela com o mesmo significado e o mesmo grão; viraram dimensões compartilhadas.
3. Tempo, Etapa, Faixa Etária e Território exigiram decisão, porque fila e população são publicadas em grão mais alto que a matrícula (mês e etapa contra dia e série; faixa de cinco anos contra idade simples) e a população em grão mais fino no território (setor censitário contra distrito). Em vez de forçar um grão único, cada fato manteve o seu, e as dimensões de grão mais alto foram definidas como rollups encolhidos conformados: Ano Letivo e Tempo contêm um subconjunto dos atributos de Data; Etapa, de Série; Faixa Etária, de Idade; e Território, de Setor Censitário. A conformidade é garantida pelos valores dos atributos comuns (ano, mês, código da etapa, faixa IBGE, distrito).
4. Território exigiu outra decisão: nos fatos Matrícula, Desfecho e Ocupação de Turma ele é o distrito da escola; no fato Fila, o distrito da planilha; no fato População, o distrito de residência. A reconciliação descrita no Apêndice A mostrou que as matrículas da planilha de fila também são contadas pelo distrito da escola, o que torna as duas primeiras leituras compatíveis. A terceira é diferente por natureza, e as consultas que a usam dizem isso explicitamente.
5. As consultas de drill-across agregam cada fato até o grão comum e unem os resultados pelos atributos das dimensões conformadas.

Outros aspectos de modelagem. Chave artificial em todas as 14 dimensões; três tabelas bugiganga (Perfil do Aluno, Deficiência e Situação da Matrícula); dimensões degeneradas (id da turma e código da matrícula no fato Matrícula, id da turma no fato Ocupação de Turma, formato da

planilha no fato Fila); tabela de fatos sem fato (Matrícula, com campo artificial); fatos agregados (Desfecho e Ocupação de Turma); dimensão com visão para dois papéis (Data); dimensão de mudança lenta tipo 2 (Escola); fatos semiaditivos (Fila e População) e não aditivos derivados (taxas e alunos por turma); membro "não informado" em Território, Data, Idade e Turno.

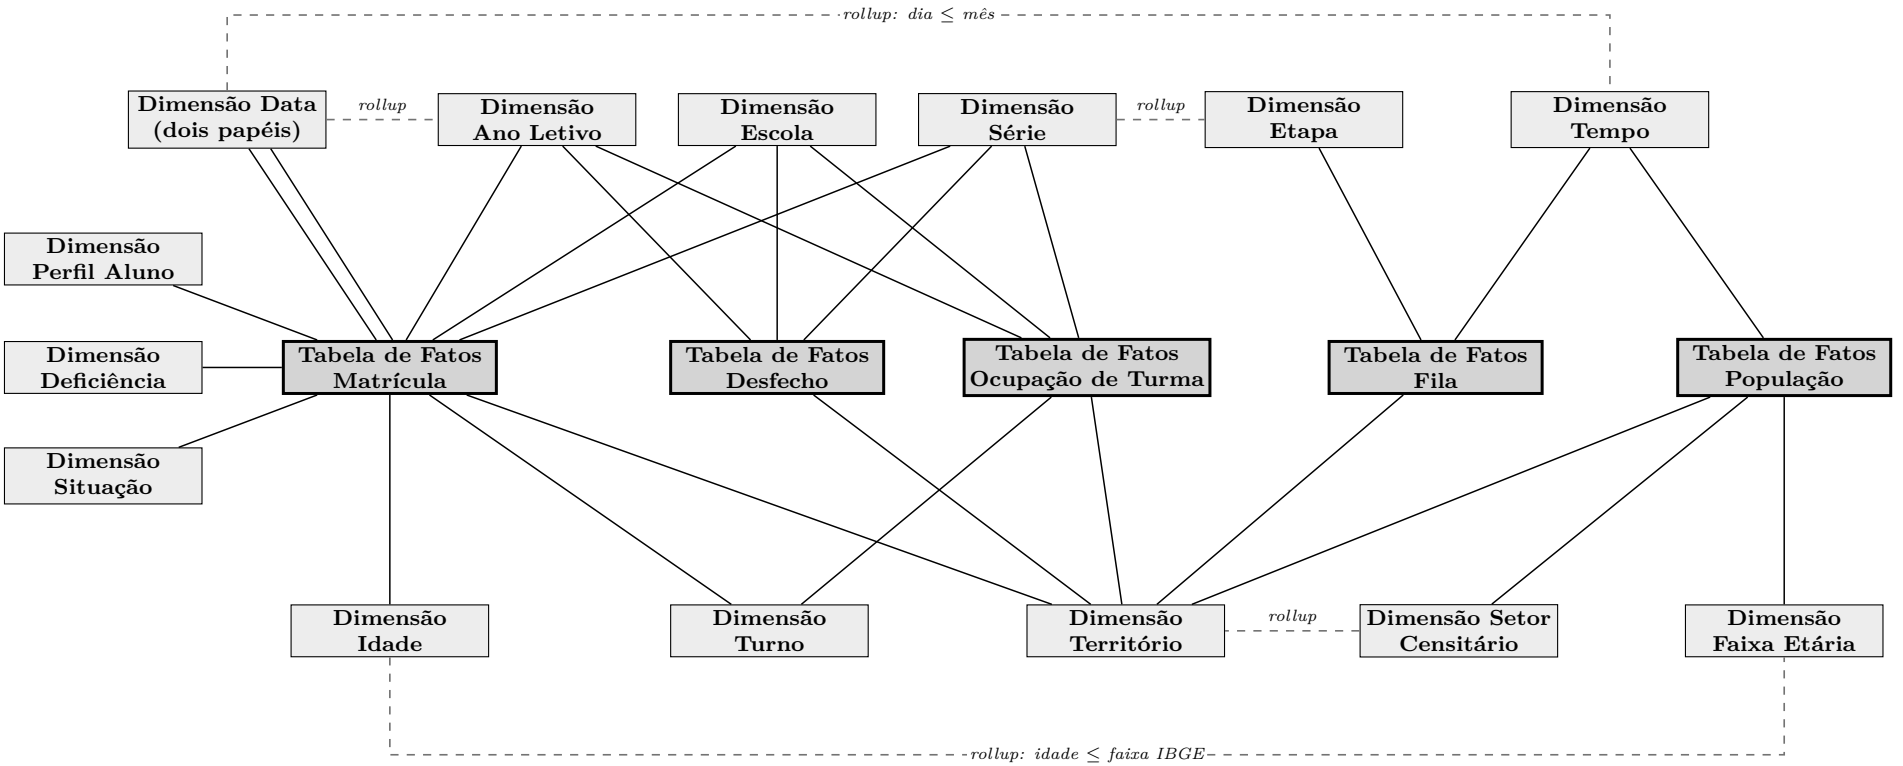


Figura 6: Constelação de fatos. Linhas contínuas ligam fatos a dimensões; as duas linhas entre o fato Matrícula e a dimensão Data são os dois papéis. Linhas tracejadas ligam cada dimensão ao seu rollup encolhido conformado (Ano Letivo também é rollup de Tempo, pelo atributo ano).

3 Consultas

As consultas a seguir estão especificadas na forma textual, conforme o enunciado. O modelo foi desenhado para respondê-las.

3.1 Consulta 1: drill-down

Consulta. No último mês publicado, quantas crianças esperavam vaga em creche no município, em cada Diretoria Regional de Educação e, dentro de cada DRE, em cada distrito?

Operação. Drill-down na hierarquia distrito $\leq$ DRE $\leq$ município da dimensão Território, sobre o fato Fila, com a dimensão Etapa fixada em creche.

Importância e justificativa. A DRE é a instância que administra a rede; o distrito é a menor unidade em que a fila é publicada e, por isso, a mais fina para localizar onde falta vaga. A hierarquia distrito, DRE só existe porque foi construída na integração com o microdado, já que a planilha de fila traz apenas o distrito.

3.2 Consulta 2: roll-up

Consulta. Qual o número de matrículas da rede municipal em cada ano de 2015 a 2024, por etapa de ensino, subindo para o nível de ensino e para o total do ano?

Operação. Roll-up na hierarquia série $\leq$ etapa $\leq$ nível da dimensão Série, sobre o fato Matrícula, para cada ano letivo.

Importância e justificativa. Mostra em quais etapas a rede cresceu e em quais encolheu, o que pode ser comparado com a evolução da fila em cada etapa. Como a quantidade de matrículas é aditiva, a soma é válida em qualquer nível.

3.3 Consulta 3: slice and dice

Consulta. Na creche, como as matrículas se dividem entre rede direta e rede conveniada e entre jornada integral e parcial, em 2019 e em 2024?

Operação. Slice na dimensão Série (etapa igual a creche); dice nas dimensões Escola (rede direta ou conveniada) e Ano Letivo (2019 e 2024), cruzando rede por jornada da dimensão Turno, sobre o fato Matrícula.

Importância e justificativa. A rede conveniada tem papel central na oferta de creche, e a jornada importa porque vaga de período parcial não atende famílias em que os responsáveis trabalham o dia inteiro. É a consulta que responde à oferta escolar por setor da rede. 2019 é o último ano antes da pandemia.

3.4 Consulta 4: pivot

Consulta. No ano mais recente, quantas matrículas cada DRE tem em jornada integral, parcial diurna e noturna, com a jornada nas colunas e a DRE nas linhas?

Operação. Pivot do eixo jornada (dimensão Turno) para as colunas, mantendo a DRE (dimensão Escola) nas linhas, sobre o fato Matrícula. Girando de novo, a etapa pode substituir a DRE nas linhas.

Importância e justificativa. Com a jornada nas colunas, a tabela mostra de relance quais regiões dependem de turno parcial e quais concentram jornada integral. Num resultado sem pivot, a jornada ficaria repetida nas linhas e a comparação entre regiões exigiria leitura linha a linha.

3.5 Consulta 5: drill-across

Consulta. Em cada distrito e ano, quantas crianças esperavam vaga em creche e em pré-escola em junho, quantas estavam matriculadas na mesma data, e qual a fração da demanda que ficou fora da rede?

Operação. Drill-across entre os fatos Fila e Matrícula. Cada fato é agregado até distrito, etapa e ano; a fila pelo mês de junho (dimensão Tempo) e a matrícula pelas matrículas ativas no fim de junho, usando os dois papéis da dimensão Data (início anterior e fim posterior à data). Os resultados são unidos pelas dimensões conformadas Território, Etapa (rollup de Série) e Tempo (rollup de Data).

Importância e justificativa. É a pergunta central do tema. Junho é publicado em todos os anos e cai no meio do ano letivo; em dezembro o ano já terminou e quase nenhuma matrícula está ativa. A fila é estoque e por isso entra pelo valor de um único mês.

3.6 Consulta 6: drill-across

Consulta. Em cada DRE e ano, qual foi a fila de creche em junho por mil matrículas de creche, e qual foi a taxa de abandono no ensino fundamental?

Operação. Drill-across entre os fatos Fila, Matrícula e Desfecho, cada um agregado até DRE e ano. A fila sobe de distrito para DRE pela hierarquia da dimensão Território. A taxa de abandono é recalculada a partir das contagens de abandonos, aprovados e reprovados, restrita ao nível ensino fundamental da dimensão Série.

Importância e justificativa. Fila e abandono são sintomas diferentes de vulnerabilidade territorial: falta de vaga no começo da trajetória escolar e evasão no meio dela. Cruzar os três fatos permite verificar se as regiões que mais sofrem com um sofrem também com o outro. A taxa é restrita ao fundamental porque na educação infantil não há aprovação.

3.7 Consulta 7: drill-across

Consulta. Em cada distrito, quantas crianças de 0 a 4 anos o Censo 2022 contou, quantas crianças dessa idade estavam matriculadas em escolas municipais do distrito na data de referência do Censo, e quantas esperavam vaga em creche ou pré-escola no último mês publicado antes dela?

Operação. Drill-across entre os fatos População, Matrícula e Fila, cada um agregado até distrito. A população é filtrada na faixa 0 a 4 anos da dimensão Faixa Etária e sobe de setor censitário para distrito pela hierarquia da dimensão Setor Censitário; a matrícula é filtrada pela faixa IBGE da dimensão Idade (conformada com Faixa Etária) e conta as ativas em 31/07/2022 pelos dois papéis da dimensão Data; a fila é a de creche e pré-escola no último mês publicado até julho de 2022 (dimensão Tempo). Saem duas razões: matrículas por 100 crianças residentes e fila por mil crianças residentes.

Importância e justificativa. A fila mede quem pediu vaga; a população mede quantas crianças existem. Um distrito com fila baixa e poucas matrículas por criança residente pode ter demanda que não chega a virar pedido de vaga, ou pode estar sendo atendido por escolas de distritos vizinhos. É a consulta que liga a política de expansão de vagas ao tamanho da população e que usa a população em idade escolar registrada como assunto de interesse. A matrícula é contada pelo distrito da escola e a população pelo distrito de residência, por isso a razão é oferta por criança residente, não taxa de atendimento dos moradores.

3.8 Consulta 8: drill-down

Consulta. Em 2019 e no ano mais recente, quantos alunos em média havia por turma em funcionamento em 30 de junho, em cada etapa da educação infantil e do ensino fundamental, no município, em cada DRE e em cada distrito?

Operação. Drill-down na hierarquia distrito $\leq$ DRE $\leq$ município da dimensão Território, sobre o fato Ocupação de Turma, com slice nas etapas creche, pré-escola e fundamental (dimensão Série) e dice em dois anos (dimensão Ano Letivo). A média de alunos por turma é recalculada em cada nível a partir das somas.

Importância e justificativa. A fila diz onde falta vaga; a ocupação diz se a vaga que existe está cheia. Onde as turmas já estão acima da média da etapa, abrir vaga exige turma nova, e não

só aproveitar lugar em turma existente. É a consulta que responde à capacidade e ocupação das turmas, medindo a ocupação efetiva, já que a capacidade não é publicada.

Consulta	**Operação**	**Fatos**	**Assuntos de interesse**
1	drill-down	Fila	fila
2	roll-up	Matrícula	matrículas
3	slice and dice	Matrícula	matrículas; oferta por setor
4	pivot	Matrícula	matrículas; oferta por setor
5	drill-across	Fila, Matrícula	fila; matrículas
6	drill-across	Fila, Matrícula, Desfecho	fila; matrículas
7	drill-across	População, Matrícula, Fila	população; matrículas; fila
8	drill-down	Ocupação de Turma	ocupação das turmas; oferta por setor

Tabela 6: Cobertura das operações exigidas: três roll-up ou drill-down, um slice and dice, um pivot e três drill-across.

A Viabilidade: o modelo povoado com os dados reais

O enunciado recomenda fortemente o uso de dados reais e volumosos. Para confirmar que as fontes sustentam o modelo, os esquemas foram implementados em DuckDB e povoados com os dados de 2015 a 2024. O código, os testes e a documentação estão no repositório do grupo.

Tabela	**Linhas**
Fato Matrícula	13.412.178
Fato Fila	33.792
Fato Desfecho	159.369
Dimensão Escola (versões)	9.927
Dimensão Data	4.384
Dimensão Série	122
Dimensão Território	97

Tabela 7: Volumes da última carga com os dados reais.

Os fatos Ocupação de Turma e População foram acrescentados ao modelo depois dessa carga. O código que os povoa está implementado e testado com dados sintéticos no layout das fontes; seus volumes e resultados reais serão medidos na próxima carga, e nenhum número deles é apresentado antes disso.

Reconciliação entre as fontes da SME. A planilha de fila publica também a matrícula por distrito e etapa. Contando no microdado as matrículas ativas no fim de junho pelo distrito da escola, as duas fontes concordam com diferença abaixo de 1% em todos os anos de 2015 a 2020 (na creche: +0,03% em 2015, +0,17% em 2019, −0,89% em 2020). Isso confirma a integração e mostra que a planilha conta a matrícula pelo distrito da escola. De 2022 em diante a concordância cai (+8,6% na creche em 2022), porque o arquivo publicado passou a trazer vínculos encerrados sem data de fim; contando alunos distintos, a diferença de 2022 cai para −2,5%. Por isso a fração de demanda fora da rede da Consulta 5 usa a matrícula da própria planilha, e a do microdado é apresentada ao lado como comparação.

Resultado preliminar. A fila de creche em junho caiu de 124.741 crianças em 2015 para 3.633 em 2024; a fração da demanda fora da rede passou de 34% para 1%. No mesmo período, as matrículas de creche passaram de 320 mil para 474 mil, e 85% delas estão na rede conveniada, quase todas em jornada integral.